

INTELIGENCIA ARTIFICIAL (1INF24)

2025-1

EXAMEN 1 - Parte 2

Indicaciones generales:

- Duración: **100 minutos (1:50 min)**.
- Para responder las preguntas de esta parte **SOLO SE PERMITE LOS NOTEBOOKS DADOS EN CLASE**
- Es **OBLIGATORIO DESHABILITAR ASISTENCIA DE IA** (Tools->Settings->AI Assistant). De no hacerlo puede ser anulada su evaluacion. Se verificara ello en los logs y remotamente con AB Tutor.
- Cualquier indicio de plagio resultará en la anulación de la prueba.
- Subir el cuadernillo con el nombre **Examen1-Parte2_código.ipynb**, donde código es su código PUCP de 8 dígitos.
- Se tomará en cuenta en la calificación la precision de la respuesta y el uso adecuado del lenguaje.

✓ Preparacion de datos y Construcccion de Modelos de Regresion (10 puntos)

Se dispone de un conjunto de datos (**forestfires.xlsx**) de incendios forestales ocurridos en el Parque Natural Montesinho (Portugal), los cuales utilizaremos para construir predictores del área quemada (variable **area**) de incendios de acuerdo a los atributos del mismo. El mapa ha sido dividido en un grillado de 9x9. Los atributos que se tiene son los siguientes:

ATRIBUTOS:

- X = Coordenada espacial X de la grilla donde ocurrió el incendio (entre 1 a 9),
- Y = Coordenada espacial Y de la grilla donde ocurrió el incendio (entre 1 a 9),
- month = mes de ocurrencia del incendio (de 'jan' a 'dec'),
- day = día de la semana de ocurrencia del incendio,
- FPMC = índice de humedad del combustible fino (FPMC). Representa el estado de humedad de la hojarasca a profundidades de 1 a 5 cm con un intervalo de 16 horas. Su rango es de 1 a 101,
- DMC = índice de humedad de la hojarasca. Representa el estado de humedad del material orgánica bajo la hojarasca a profundidad de 5 a 10 cm con un intervalo de 360 horas. Su rango es de 0 a 300,
- DC = Representa el estado de humedad del suelo profundo a profundidades de 10 a 20 cm con un intervalo de 52 días. Su rango es de 0 a 1200,
- ISI = índice de propagación inicial (ISI) es la combinación de la velocidad del viento y el índice de humedad del combustible (FMC). No tiene unidades y es abierto. Se utiliza para estimar el potencial de propagación,
- temp = temperatura (grados centigrados),
- RH = humedad relativa. Su rango es de 0 a 100,
- wind = velocidad del viento (km/h) ,
- rain = cantidad de lluvia (mm/m2)
- area (Variable Target) = área quemada en hectareas (de 0 a 1090.84 ha)

Con este dataset se requiere que usted haga el preprocesamiento y evaluacion de algoritmos de regresion para predecir el área quemada (area) con base a las otras variables. **Es importante que los modelos que usted evalúe puedan servir para predecir el área quemada de incendios nuevos que puedan ocurrir dentro del Parque Natural Montesinho**

Se le pide que elabore y ejecute código en Python para realizar las siguientes tareas:

1) Limpiar el dataset con el fin de obtener un conjunto de datos limpio y con informacion relevante. Los pasos que puede elegir aplicar aqui pueden ser: dropeos de columnas, dropeos de filas, remoción de outliers, filas duplicadas y datos inconsistentes, imputacion de nulos. Cada paso elegido debe ser justificado. Se valora el uso de plots adecuados para esta etapa (2 puntos)

RESPUESTA

2) Codifique cada variable categorica con la codificacion adecuada (Label Encoding o OneHot Encoding). Justifique sus elecciones (1 punto)

RESPUESTA

3) Genere e interprete un plot de correlaciones entre las variables. Si observa pares de variables con correlaciones elevadas (mayores a 0.90) escoja solo una de ellas (1 punto)

RESPUESTA

4) Dividir el dataset procesado en dos conjuntos: train y test. Usar 80% de los datos para train y 20% para test (0 puntos)

RESPUESTA

5) Con el conjunto de train evalúe en crossvalidación los siguientes algoritmos de regresión: Linear Regression, Ridge Regression, Lasso Regression, ElasticNet Regression, KNN (K=5), KNN (K=10), Decision Tree Regression (max_depth=20), Decision Tree Regression (max_depth=None). Use 10 folds para la crossvalidación y como métrica de scoring use 'neg_mean_squared_error'. Muestre boxplots de los resultados de la crossvalidación de todos los algoritmos evaluados y comente los resultados. (2 puntos)

RESPUESTA

6) Con base a los resultados del paso 5 escoja el algoritmo que mejores modelos induce y entrene con él un modelo final usando todos los datos de entrenamiento y evalúelo en la data separada para prueba (paso 4). Muestre las métricas MAE y R2 en el conjunto de test. Muestre un scatter plot de los valores reales vs los predichos en el conjunto de test y comente los resultados. (1 punto)

RESPUESTA

7) Muestre plot de distribución de la variable target y comente sobre si existe algún sesgo y cómo se relaciona ello con los resultados obtenidos en el paso 6. Comente de forma justificada qué mejoras propone para mejorar los resultados (2 puntos)

RESPUESTA:

8) Explique brevemente ¿por qué se hace crossvalidación en el conjunto de train para evaluar los algoritmos de machine learning? ¿Por qué no simplemente se entrena modelos con todo train y se los evalúa en el conjunto de test? (1 punto)

RESPUESTA: