

INTELIGENCIA ARTIFICIAL (1INF24)



UNIDAD 2: Fundamentos de Machine Learning y Redes Neuronales Artificiales


Tema 2: Preprocesamiento y Reducción Dimensional (Parte 1)

Contenido

- Motivación
- Exploración Inicial
- Limpieza de Datos
- Transformación de Datos




Recapitulando el flujo de trabajo de ML...



Diferentes marcos de trabajo hacen referencia a una etapa de preparación o preprocesamiento de los datos, el cual es vital para el éxito del proyecto de desarrollo de una solución analítica.

“The *truth* (**data**) is out there..”



Fotos de Autores desconocidos están bajo licencia [CC BY-NC-ND](https://creativecommons.org/licenses/by-nc-nd/4.0/)

¿Cómo estructuramos los datos?

Atributos/variables/características/dimensiones

Etiqueta de
clase/variable
objetivo/target

Observaciones/registros

Estación	Temp.	Humedad	Viento	Alerta
San Miguel	20	75	57	No
San Borja	30	80	40	Sí
Miraflores	23	90	45	No
Comas	20	87	60	No


Un conjunto de datos está formado por un grupo finito de registros (entidades o observaciones), cada uno descrito por un conjunto de atributos (o variables)



¿Cómo pueden ser los atributos?



¿Cómo pueden ser los atributos?



Pueden tener orden o carecer de él

Calidad de Data = ?



Calidad de Data = Calidad de Resultado

Los datos en la realidad son sucios:


Ruidosos



Incompletos



Con valores atípicos




Es necesario procesar los datos antes de usarlos para garantizar resultados de calidad.

¿Cómo identificamos problemas en la data? => **Análisis Exploratorio de Datos (EDA)**

¿Qué implica un EDA inicial?

1. Estadísticas descriptivas


Conocer tendencia central + dispersión → Revelar alteraciones de distribución



Mediana (Q2)

```
df.describe()
```

	temperature	windspeed
count	6.000000	6.000000
mean	30.500000	4.666667
std	3.885872	2.338090
min	24.000000	2.000000
25%	29.000000	2.500000
50%	32.000000	5.000000
75%	32.000000	6.750000
max	35.000000	7.000000




Media


¿Qué implica un EDA inicial?

2. Distribución de la variable numérica

- Identificar si la variable tiene una distribución conocida o no → propiedades y operaciones únicas dependiendo la distribución.
- **Visualmente:** histograma de frecuencias `[plt.hist(x, bins=N, ...)]`



Distribución Normal




Distribución Chi Cuadrado

¿Qué implica un EDA inicial?

2. Distribución de la variable numérica



- Identificar si la variable tiene una distribución conocida o no → propiedades y operaciones únicas dependiendo la distribución.
- Visualmente: diagramas de densidad
`[seaborn.kdeplot(df[variable])]`



¿Qué implica un EDA inicial?

2. Distribución de la variable numérica


- Identificar datos atípicos, diferentes a la mayoría de la población.
- **Visualmente:** diagramas de caja [`plt.boxplot(x, ...)`]



¿Qué implica un EDA inicial?

3. Asimetría de la variable numérica

- Identificar sesgo hacia algún valor.
- **Analíticamente:** coeficiente de asimetría `[df[columna].skew()]`



Tipos de Asimetría

¿Qué implica un EDA inicial?

4. Distribución de la variable categórica

- Identificar frecuencias por categoría.
- **Visualmente:** diagrama de barras `[plt.bar(x, y, ...)]`
- **Analíticamente:** tabla de frecuencias `[df[columna].value_counts(dropna=False)]`





Diagrama de Barras para frecuencias

¿Qué implica un EDA inicial?


5. Correlaciones

- Indicio del grado de relación entre dos variables.
- Usado para selección de variables → correlación fuerte con variable dependiente, débil con independientes.
- **Analíticamente:** coeficiente de correlación `[df.corr(method='pearson')]`


$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$



R = -1



R = 0







R = +1

¿Qué involucra la limpieza de datos?

1. Valores atípicos

Outliers: ocurrencias inusuales, raras, distintas que no se ajustan al patrón. Generalmente se definen como valores atípicos, que escapan al rango donde se concentran la mayoría de los datos.

Pueden encontrarse en 1 o más dimensiones.




Foorthuis R. (2021). On the nature and types of anomalies: a review of deviations in data. International journal of data science and analytics, 1–35. Advance online publication. <https://doi.org/10.1007/s41060-021-00265-1>

¿Qué involucra la limpieza de datos?

1. Valores atípicos

- Identificar valores muy diferentes a la mayoría de la población.
- **Opciones:** mantenerlos, eliminarlos o suavizarlos.
- **Visualmente:** diagrama de cajas [`plt.boxplot(x, ...)`]



- Otra librería: PyOD.
- <https://pyod.readthedocs.io/en/latest/>
- <https://github.com/yzhao062/anomaly-detection-resources>
- Zhao, Y., Nasrullah, Z. and Li, Z., 2019. PyOD: A Python Toolbox for Scalable Outlier Detection. Journal of machine learning research (JMLR), 20(96), pp.1-7.

¿Qué involucra la limpieza de datos?

2. Vacíos


- Algunas observaciones pueden venir con datos vacíos (*missing values*).
- **Analíticamente:** conteo de datos vacíos `[df.isnull().sum() o df.isnull().mean()]`
- **Estrategia 1:** eliminar la fila o la columna `[df.dropna(axis=?)]`

Nº Muestra	Altura (cm)	Peso (kg)	Sexo	Edad
0	185	90	V	29
1	NaN	60	M	34
2	174	70	V	23
3	162	55	M	21
4	183	85	NaN	50
5	179	84	V	64

Nº Muestra	Altura (cm)	Peso (kg)	Sexo	Edad
0	185	90	V	29
2	174	70	V	23
3	162	55	M	21
5	179	84	V	64

Nº Muestra	Peso (kg)	Edad
0	90	29
1	60	34
2	70	23
3	55	21
4	85	50
5	84	64

`df.dropna(axis=0)`



`df.dropna(axis=1)`

¿Qué involucra la limpieza de datos?

2. Vacíos

- Estrategia 2: completar (imputar) los vacíos `[df.fillna(valor_relleno)]`
- Valores de relleno: media, mediana, constante, valor anterior/posterior, moda

Nº Muestra	Altura (cm)	Peso (kg)	Sexo	Edad
0	185	90	V	29
1	NaN	60	M	34
2	174	70	V	23
3	162	55	M	21
4	183	85	NaN	50
5	179	84	V	64

Nº Muestra	Altura (cm)	Peso (kg)	Sexo	Edad
0	185	90	V	29
1	176.6	60	M	34
2	174	70	V	23
3	162	55	M	21
4	183	85	NaN	50
5	179	84	V	64

`df.fillna(df.mean())`

Nº Muestra	Altura (cm)	Peso (kg)	Sexo	Edad
0	185	90	V	29
1	176.6	60	M	34
2	174	70	V	23
3	162	55	M	21
4	183	85	V	50
5	179	84	V	64

`df.fillna(df.mode())`

¿Qué involucra la limpieza de datos?

2. Vacíos

- **Estrategia 3:** usar técnicas de ML para estimar el valor de la variable perdida.
- **Estrategia 4:** para variables categóricas se puede crear categoría/nivel nuevo (No Disponible, Desconocido, etc).

¿Qué involucra la limpieza de datos?

3. Otras actividades de limpieza de datos

- **Errores en la data:** corregir los errores detectados, o eliminar observaciones erróneas. Tipos de errores (lista no exclusiva):
 - **Datos inconsistentes:** se contradicen entre sí. Ejemplo: consumo_mes_1=10, consumo_mes_2=10, consumo_mes_1_y_2=0.
 - **Datos no uniformes:** tienen formatos distintos en la misma columna. Ejemplo: fechas en formato yyymmdd y dd/mm/yyyy en misma columna.
 - **Datos inválidos:** no posibles en el mundo real. Ejemplo: fecha 30 de febrero, sucursales que no existen.
 - **Datos repetidos:** aparecen más de 1 vez en el conjunto de datos.
- **Variables correlacionadas y multicorrelacionadas:** de N variables correlacionadas, mantener solo una (modelos lineales).

Es necesario transformar los datos

1. Variables nominales: encoding

- La mayoría de algoritmos de ML no admiten datos categóricos → necesidad de transformarlos en numéricos (encoding).
- Opciones: label encoding, one-hot encoding, target encoding, hash encoding, ...

ID	Color		ID	Color
41239687	Rojo	➔	41239687	1
12348765	Azul		12348765	2
00123132	Azul		00123132	2
00123132	Verde		00123132	3



Es necesario transformar los datos

1. Variables nominales: encoding

- La mayoría de algoritmos de ML no admiten datos categóricos → necesidad de transformarlos en numéricos (encoding).
- Opciones: label encoding, one-hot encoding, target encoding, hash encoding, ...

ID	Color		ID	Color_Rojo	Color_Azul
41239687	Rojo	➔	41239687	1	0
12348765	Azul		12348765	0	1
00123132	Azul		00123132	1	1
00123132	Verde		00123132	0	0



Es necesario transformar los datos

2. Variables numéricas: binarización

- Valores por encima de umbral se reemplazan por 1; caso contrario, por 0.
- En problemas de clasificación, la clase puede venir con un valor numérico y se requiere dar una categoría discreta en función de su valor. **Ejemplo:** se tiene la variable nota (0-20) y se desea tener dos categorías: 0 (desaprobado, 0-10) y aprobado (11-20). `[sklearn.preprocessing.Binarizer(threshold=?)]`

```
# binarization
binarizer = Binarizer(threshold=0.0).fit(X)
binaryX = binarizer.transform(X)
```

Sensor 1	Sensor 2	Sensor 3
0.007483	0.097278	0.995229
0.007218	-0.055335	0.998442
0.583487	0.795664	0.162669
0.001062	0.053088	-0.998589





Sensor 1	Sensor 2	Sensor 3
1.0	1.0	1.0
1.0	0.0	1.0
1.0	1.0	1.0
1.0	1.0	0.0

Es necesario transformar los datos

3. Variables numéricas: escalamiento

- En muchos conjuntos de datos, las variables se presentan en diferentes escalas. Ejemplo: edad 0-120; monto de transacción: 0-10000; MB usados: 1000-1000000.
- En algunos algoritmos de ML, la variable con mayor variabilidad puede tener mayor influencia en resultados solo por su escala → llevar todo a escalas similares para mitigar riesgo.



Es necesario transformar los datos

3. Variables numéricas: escalamiento por columna

- **Estrategias:** re-escalamiento [`sklearn.preprocessing.MinMaxScaler`] y estandarización [`sklearn.preprocessing.StandardScaler`].

Estandarización

$$X' = \frac{X - \mu}{\sigma}$$

Aplicable si datos siguen una distribución normal o próxima a ella.

Lleva los datos a tener media 0 y desviación estándar 1.

No altera la distribución original.

Aplicable para analizar el valor de la variable en diferentes momentos y analizar sus tendencias a lo largo del tiempo.

Re-escalamiento

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

No depende de una distribución normal de los datos.

Lleva los datos al rango entre 0 y 1.

Altera la distribución original.

Aplicable para cuando las variables presentan distintas escalas y/o unidades de medida.



Es necesario transformar los datos

3. Variables numéricas: escalamiento por fila

- Estrategias: normalización [`sklearn.preprocessing.Normalizer`]

Norma L1

$$X_{norm} = \frac{X_i}{\sum |X_i|}$$

Suma de valores absolutos = 1

Usado cuando valores pequeños son relevantes.

Resultado frecuentemente disperso (muchos iguales o cercanos a 0)

Ejemplo: si $X=[3,4] \rightarrow X_{norm}=[3/7, 4/7]$

Norma L2

$$X_{norm} = \frac{X_i}{\sum |X_i|^2}$$

Longitud euclideana = 1

Usado con algoritmos sensibles a magnitudes (KNN, SVM)

Preserva dirección, reduce influencia de escala.

Ejemplo: si $X=[3,4] \rightarrow d=\sqrt{3^2+4^2}=5 \rightarrow X_{norm}=[3/5; 4/5]$



Es común dividir el conjunto de datos

- Con frecuencia suele dividirse el conjunto de datos en 2 subconjuntos: uno de entrenamiento y otro de pruebas.
- El conjunto de entrenamiento **puede** volverse a dividir en 2 subconjuntos: entrenamiento y validación.
- El conjunto de prueba **no debe** ser usado en ninguna toma de decisión en el entrenamiento del modelo.
- Escalamiento (scaling) y codificación (encoding) deben ser construidos con el subconjunto de entrenamiento y aplicarlos directamente sobre el de prueba.
- En Python: `[sklearn.model_selection.train_test_split(X, y, test_size=?, stratify=y)]`



¡Gracias!

