

INTELIGENCIA ARTIFICIAL (1INF24)




UNIDAD 2: Fundamentos de Machine Learning y Redes Neuronales Artificiales

Tema 2: Preprocesamiento y Reducción Dimensional (Parte 2)

Contenido

- La maldición de la dimensionalidad
- Reducción de Dimensionalidad

Recapitulando el flujo de trabajo de ML...



Diferentes marcos de trabajo hacen referencia a una etapa de preparación o preprocesamiento de los datos, el cual es vital para el éxito del proyecto de desarrollo de una solución analítica.

¿Cómo estructuramos los datos?


Atributos/variables/características/dimensiones

Etiqueta de
clase/variable
objetivo/target

Observaciones/registros


Estación	Temperatura	Humedad	Viento	Alerta
San Miguel	20	75	57	No
San Borja	30	80	40	Sí
Miraflores	23	90	45	No
Comas	20	87	60	No

Un conjunto de datos está formado por un grupo finito de registros (entidades o observaciones), cada uno descrito por un conjunto de atributos (o variables)



¿Qué pasa cuando la dimensionalidad crece?

Crece exponencialmente la cantidad de espacios sin muestra.




- Con el aumento de dimensiones, el número de espacios crece exponencialmente.

¿Qué pasa cuando la dimensionalidad crece?


Este problema ocurre, sobretodo, cuando las dimensiones crecen más que la cantidad de instancias en la población.

Si las muestras incrementan cuando aumenta la dimensionalidad, es probable que ninguna celda quede vacía.



El problema aparece cuando el número de muestras se mantiene constante o crece poco, mientras la dimensionalidad aumenta.

- Con el aumento de dimensiones, el nro. de celdas crece exponencialmente.
- Las muestras se vuelven muy escasas.




Problema de “*large p, small n*”: muchas dimensiones y pocas instancias

¿Qué pasa cuando la dimensionalidad crece?

Maldición de la Dimensionalidad



- **Problema:** en espacios dispersos (sparse), las distancias parecen las mismas (instancias equidistantes). “A medida que aumenta el ratio p/n , el espacio se vuelve más vacío y las distancias tienden a ser iguales (equidistantes)”.
- Afecta algoritmos que miden la similitud de datos por distancia (KNN, K-Means, detección de outliers, ...). También impacta desempeño de otros algoritmos.



Alta dimensión



Espacio equidistante




Buscar: fenómeno de la distancia constante

¿Cómo reducimos la dimensionalidad?

Reducción de la dimensionalidad – Selección de atributos


- Mejoran la precisión e interpretabilidad del modelo.
- Reducen costo computacional y tiempo de entrenamiento.
- Facilitan seguimiento de atributos realmente importantes.



¿Cómo reducimos la dimensionalidad?

Selección de atributos

- Selección de un subconjunto óptimo de atributos de acuerdo a determinado **criterio de selección**.
- **Ventaja:** interpretabilidad de las variables se mantiene.



¿Cómo reducimos la dimensionalidad?

Selección de atributos – Métodos de Filtro

- Evalúan la relevancia de los atributos de manera independiente o respecto al target. Miden propiedades intrínsecas y no involucran el uso de algoritmos de ML.
- **Ventajas:** menor coste computacional.
- **Desventajas:** menos precisos.
- Ejemplos (*tarea: investigar cada método e implem. En Python*):
 - Umbral de varianza
 - Prueba chi-cuadrado
 - Coeficientes de correlación
 - Information Value

¿Cómo reducimos la dimensionalidad?

Selección de atributos – Métodos de Envoltorio

- Emplean un algoritmo de ML para evaluar la precisión del modelo con un subconjunto específico de características.
- Se pueden emplear heurísticas y metaheurísticas para navegar el espacio combinatorio de características.
- **Ventajas:** más precisos para el modelo.
- **Desventajas:** mayor coste computacional.
- Ejemplos (*tarea: investigar cada método e implem. En Python*):
 - Forward Feature Selection
 - Backward Feature Elimination
 - Permutation Importance
 - Metaheurísticas con representación discreta



¿Cómo reducimos la dimensionalidad?


Selección de atributos – Métodos Empaquetados

- La selección de atributos es parte del modelo: en el proceso de entrenamiento se generan y comparan diferentes combinaciones de subconjuntos de las variables.
- Representan un punto intermedio entre los métodos de filtro y los métodos de envoltorio.
- Ejemplos (*tarea: investigar cada método e implem. En Python*):
 - Métodos de ensamble (como Random Forest): combinan modelos que asignan implícitamente un puntaje a subconjuntos de atributos en base a la precisión del modelo.
 - Regresión Lasso: modelo lineal, hace cero los coeficientes de las variables con menor impacto en la variable dependiente.

¿Cómo reducimos la dimensionalidad?

Reducción de la dimensionalidad – Transformación de atributos

- Buscan representar los datos en un espacio de menor dimensión, que represente la información relevante.
- **Ventajas:** simplifican el aprendizaje, así como la visualización e interpretación.
- **Desventajas:** pérdida de interpretabilidad de las variables.
- Tipos:
 - **Lineales:** extraen información buscando proyecciones lineales. Ejemplo: **PCA**, LDA, Factor Analysis, ICA.
 - **No lineales:** extraen información buscando mantener la topología y geometría de los datos. Ejemplo:



Principal Component Analysis (PCA)

¿Qué es?

- Técnica de aprendizaje no supervisado que transforma un conjunto de características correlacionadas en observaciones no correlacionadas.
- Lo anterior se consigue identificando un conjunto de ejes ortogonales de rotación llamados componentes principales.
- Los componentes se ordenan según la proporción de varianza explicada por cada uno



Principal Component Analysis (PCA)

Intuición

Repasemos la representación de datos en un gráfico...

1 D: punto en una recta

Estación	Temp.
San Miguel	10
Miraflores	0
Ate	14
...	...



A pesar de ser 1 dimensión, hay información útil disponible.





Principal Component Analysis (PCA)

Intuición


Repasemos la representación de datos en un gráfico...

2 D: punto en un plano

Estación	T.	H.
San Miguel	10	60
Miraflores	0	10
Ate	14	74
...	...	...



Con correlación



Sin correlación


Principal Component Analysis (PCA)

Intuición

Repasemos la representación de datos en un gráfico...

3 D: punto en el espacio

Estación	T.	H.	P.
San Miguel	10	60	20
Miraflores	0	10	10
Ate	14	74	20
...	...	...	...



Principal Component Analysis (PCA)

Intuición

En general:

1D → Recta numérica

2D → Plano XY

3D → Plano XY + Profundidad

4D → ?

5D → ?

200D → ?


¿Realmente necesitamos todas las dimensiones? ¿O podemos prescindir de algunas?



Principal Component Analysis (PCA)


Intuición

¿Qué pasaría si la data en 2 dimensiones fuera similar a esto?



Puede verse que la variabilidad de los datos se da principalmente en el eje T (de izquierda a derecha). En el eje H (arriba abajo), la variación es poca.

¿Y si prescindimos de la variación en H?



Al eliminarse la variación en H, el gráfico parece transmitir casi la misma información.

¿Y para qué necesitamos H?




De hecho, en este caso, ya no se requiere H y se puede representar los datos en función solo de T.

Principal Component Analysis (PCA)


Intuición

¿Qué pasaría si la data en 2 dimensiones fuera similar a esto?




La variabilidad, en este caso, se da en el eje diagonal entre T y H.

¿Y si rotamos los ejes?



Al rotarse los ejes, volvemos a la situación de la lámina anterior: casi toda la varianza está explicada por V (de izq. A der.) y una mínima parte por U (arriba abajo).

¿Y para qué necesitamos U?



Podemos prescindir de U sin perder mucha información.

...llevado a N dimensiones, ésta es la idea (muy simplificada) del PCA!!

Principal Component Analysis (PCA)

Objetivo del PCA:

- Sea n la cantidad de datos.
- Sea p la cantidad de variables originales.
- Sea $X_{n \times p}$ una matriz que representa el conjunto de datos completo.
- El objetivo del PCA es encontrar una matriz $S_{n \times k}$ que represente al conjunto de datos completo en k -dimensiones de un nuevo sistema (obtenido de rotar el sistema original). Se cumple que $k < p$.
- PCA devuelve un conjunto de bases de proyección, llamados componentes principales, que contienen la mayor varianza de los datos. Ellos se encuentran en la **matriz de rotación** o **matriz de pesos**.
- Los componentes principales se ordenan según la proporción de la varianza total explicada por cada uno.

Principal Component Analysis (PCA)

Supuestos del PCA:

- Linealidad de los datos
- Varianza grande = Aporte de información grande
- Correlación entre variables
- Data centrada, si se usa la matriz de covarianza

Principal Component Analysis (PCA)

Herramientas matemáticas del PCA: vectores y valores propios

- Imagina que se aplica una transformación lineal (una matriz A) a varios vectores del espacio. La mayoría cambia de dirección y magnitud tras el cambio.
- Un **vector propio** es un vector especial que, al ser transformado por una matriz A , cambia de magnitud (se escala), pero su dirección se mantiene (recordar que dirección no es lo mismo que sentido).
- Los vectores propios indican en qué ejes la transformación solo escala al vector.
- Un **valor propio** es un número escalar que se asocia a cada vector propio e indica la magnitud del escalamiento.
- Para encontrar los valores (λ) y vectores $\mathbf{v}$ propios de una matriz A :

$$A\mathbf{v} = \lambda\mathbf{v}$$



Principal Component Analysis (PCA)

Algoritmo (para n datos con p variables)

- Calcular la matriz de covarianza C:

$$Cov = \frac{1}{n-1} X^T X$$


```
from sklearn.decomposition import PCA

# Utilizando PCA de scikit-learn para reducir a 2 componentes
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_std)
```

- Calcular los autovalores (*eigenvalues*) y autovectores (*eigenvector*) de la matriz de covarianza. Para ello, se resuelve la ecuación siguiente: $(C - \lambda I)v = 0$. λ representa cada autovalor y v es el autovector para un autovalor determinado. I es la matriz identidad.
- Ordenar los autovectores de manera descendente según sus autovalores.
- Seleccionar los k primeros autovectores. Esta es la matriz de rotación, matriz de pesos o matriz de proyección Q .
- Normalizar la matriz. Proyectar los datos: $S_{n \times k} = X_{n \times p} * Q_{p \times k}$

Principal Component Analysis (PCA)

Algunos puntos a considerar



1) PCA devuelve una serie de **componentes ortogonales entre sí**.

$$q_1 \perp q_2 \perp \dots \perp q_k$$

2) PCA devuelve **varianza explicada** de las componentes, cuya sumatoria es igual a la varianza total de la matriz X original.

ve = `fit_pca.explained_variance_`

$$\sum_{i=1}^p \text{var}(X_i) = \sum_{i=1}^k \text{var}(ve_i)$$

3) PCA devuelve un vector que representa la **proporción de varianza acumulada** por cada componente. Con esto se identifica aquellas direcciones de proyección en las que la varianza es mayor.

Principal Component Analysis (PCA)


Sobre los componentes principales

- Se requiere que los componentes principales sean **ortonormales**.
 - Los vectores propios de la matriz de covarianza son ortogonales (la matriz es simétrica).
 - Los vectores propios de la matriz de covarianza se normalizan al finalizar el procedimiento.
- Importancia:
 - **Ortogonalidad:** redundancia
 - Normalidad: comparabilidad



Principal Component Analysis (PCA)

Determinando el valor de k

Podemos evaluar la calidad de la transformación del espacio empleando diagramas de sedimentación (scree plots) o diagramas de codo.



Scree plot



Diagramas de codo

En ambos casos, la idea es ver cuánto de la varianza total es explicada por los primeros 2 componentes principales. El mejor caso se da cuando la mayor parte está explicada por PC1 y PC2.

Principal Component Analysis (PCA)

Puntos a considerar:

- Para un dataset con N observaciones y P variables, la cantidad de componentes principales será $\min(N-1, P)$.
- El PCA es un método de reducción de dimensionalidad, no de selección de variables.
- El espacio de PCA es completamente nuevo, formado por combinaciones lineales de las dimensiones originales.

Principal Component Analysis (PCA)




Figura: Transformación de datos con PCA (Mueller 2016)


¡Gracias!



Anexo: PCA - Detalle

$$V = \begin{bmatrix} & T & H \\ PC1 & 0.97 & 0.24 \\ PC2 & -0.24 & 0.97 \end{bmatrix}$$

$$V^T = \begin{bmatrix} & PC1 & PC2 \\ T & 0.97 & -0.24 \\ H & 0.24 & 0.97 \end{bmatrix}$$

$$X = \begin{bmatrix} & T & H \\ & 2.0 & 1.0 \end{bmatrix}$$


Por fórmula: $X_t = XV^T$

$$X_t = [2.0 \ 1.0] \begin{bmatrix} 0.97 & -0.24 \\ 0.24 & 0.97 \end{bmatrix}$$

$$X_t = [PC1 \ PC2]$$

$$PC1 = 2.0(0.97) + 1.0(0.24) = 2.18$$

$$PC2 = 2.0(-0.24) + 1.0(0.97) = 0.49$$

Para retornar: $X = X_t V$

$$X = [2.18 \ 0.49] \begin{bmatrix} 0.97 & 0.24 \\ -0.24 & 0.97 \end{bmatrix}$$

$$X = [O1 \ O2]$$

$$O1 = 2.18(0.97) + 0.49(-0.24) = 2.0$$

$$O2 = 2.18(0.24) + 0.49(0.97) = 1.0$$

