

1EST22 Probabilidad y Estadística

Examen 1

Profesores del curso

Pregunta 1 (5.0 puntos)

En un sistema se modela X = tiempo hasta la primera falla e Y = tiempo hasta la segunda falla, ambos medidos en años, como un vector aleatorio (X, Y) con función de densidad conjunta

$$f_{XY}(x, y) = \begin{cases} ke^{-x-y} & , \text{ si } 0 < x < y < \infty \\ 0 & , \text{ en caso contrario} \end{cases}$$

- a) (1.0 punto) Pruebe que $k = 2$.
- b) (1.0 punto) Calcule la probabilidad de que el tiempo hasta la primera falla del sistema sea mayor a un año.
- c) (1.0 punto) Si el tiempo hasta la primera falla fue de 6 meses, calcule la probabilidad de que el tiempo hasta la segunda falla haya sido mayor a un año.
- d) (2.0 puntos) Calcule la probabilidad que el tiempo hasta la segunda falla sea mayor al doble del tiempo hasta la primera falla del sistema.

Parte a)

Se debe cumplir que $\int \int f_{XY}(x, y) dx dy = 1$, entonces

$$\int_0^\infty \int_x^\infty ke^{-x-y} dy dx = \int_0^\infty [ke^{-x}(-e^{-y})|_x^\infty] dx = \int_0^\infty ke^{-2x} dx = -k\frac{1}{2}e^{-2x}|_0^\infty = k\frac{1}{2} = 1$$

de donde obtenemos que $k = 2$.

Parte b)

Hallamos primero la función de distribución marginal de X ,

$$f_X(x) = \int_x^\infty f_{XY}(x, y) dy = \int_x^\infty 2e^{-x-y} dy = 2e^{-x}(-e^{-y})|_x^\infty = 2e^{-2x}, \quad x > 0$$

Luego, $F_X(x) = 1 - e^{-2x}$, $x > 0$. Se pide $P(X > 1) = 1 - F_X(1) = 0.1353$

Parte c)

Primero hallamos la distribución condicional,

$$f(y | X = x) = \frac{f_{XY}(x, y)}{f_X(x)} = \frac{2e^{-x-y}}{2e^{-2x}} = e^{-(y-x)}, \quad x < y < \infty$$

Luego,

$$F(y | X = x) = \int_x^y f(t | X = x) dt = \int_x^y e^{-(t-x)} dt = -e^{-(t-x)} \Big|_x^y = 1 - e^{-(y-x)}$$

Se pide $P(Y > 1 | X = 0.5) = 1 - F(1 | X = 0.5) = 0.6065$

Parte d)

$$P(Y > 2X) = \int_0^\infty \int_x^{2x} 2e^{-x-y} dy dx = \int_0^\infty 2(e^{-2x} - e^{-3x}) dx = 1/3$$

Pregunta 2 (5.0 puntos)

La velocidad del viento, en metros por segundo (m/s), en una cierta región se considera una variable aleatoria continua X . Se recolectó una muestra de 100 mediciones a partir de la cual se calcularon las siguientes estadísticas

$$\sum_{i=1}^{100} \ln(x_i) = 142, \quad \sum_{i=1}^{100} x_i = 471, \quad \sum_{i=1}^{100} x_i^2 = 2677$$

Para modelar X se propone la siguiente función de distribución acumulada:

$$F_X(x) = 1 - e^{-x^2/\alpha}, \quad x > 0$$

a) (3.0 puntos) A partir de la información brindada, halle el estimador de máxima verosimilitud de α .

b) (2.0 puntos) Un analista había pensado en utilizar para esta data mas bien un modelo Exponencial. ¿Cuál de los dos modelos presenta un mejor ajuste a los datos? Justifique su respuesta.

Solución**Parte a)**

La función de densidad de X viene dada por

$$f_X(x) = \frac{2x}{\alpha} e^{-x^2/\alpha} \quad x > 0,$$

la función de verosimilitud por

$$L(\beta) = \frac{2^n}{\alpha^n} \left(\prod_{i=1}^n x_i \right) e^{-\sum_{i=1}^n x_i^2/\alpha}$$

y la función de log-verosimilitud por

$$\ell(\alpha) = \log(L(\alpha)) = n \ln(2) - n \ln(\alpha) - \frac{1}{\alpha} \sum_{i=1}^n x_i^2 + \sum_{i=1}^n \log(x_i).$$

Maximizando, $0 = \ell'(\beta) = -\frac{n}{\alpha} + \frac{1}{\alpha^2} \sum_{i=1}^n x_i$ y como $\ell''(\beta) < 0$, el estimador MV de β es

$$\hat{\alpha}_{MV} = \frac{\sum_{i=1}^n x_i^2}{n} = 26.77.$$

Parte b)

Para el modelo inicial $\hat{\ell} = -217.4134677$, $k = 1$ y $AIC = 436.8269354$

Para el modelo exponencial $\hat{\lambda} = 0.2123142$, $k = 1$, $\hat{\ell} = -254.9687908$, $k = 1$ y $AIC = 511.9375816$.

Por lo tanto, el modelo inicial presenta un mejor ajuste.

Pregunta 3 (5.0 puntos)

En un estudio para una compañía aérea, se seleccionaron 101 vuelos al azar de aviones con capacidad para 200 pasajeros. Para cada vuelo seleccionado, la línea aérea vendió 205 pasajes. Se registró el número de pasajeros que se presentaron en cada vuelo, obteniéndose los siguientes resultados

Número de pasajeros	Número de vuelos
198	4
199	12
200	20
201	20
202	16
203	18
204	10
205	1

y las siguientes estadísticas

```
# Estadísticas - Educación
descr(pasajeros,stats=c("n.valid","mean","sd"))
```

```
## Descriptive Statistics
## pasajeros
## N: 101
##
##              pasajeros
## -----
##      N.Valid      101.00
##      Mean        201.30
##      Std.Dev      1.70
```

```
# Cuantiles t-Student
qt(c(0.90,0.95,0.975,0.99,0.995),100)
```

```
## [1] 1.290 1.660 1.984 2.364 2.626
```

```
# Cuantiles Normal
qt(c(0.90,0.95,0.975,0.99,0.995),100)
```

```
## [1] 1.282 1.645 1.960 2.326 2.576
```

- (1.0 puntos) Estime, con un nivel de confianza del 99%, la media del número personas que se presentan a un vuelo. Interprete.
- (2.0 puntos) Evalúe, usando un nivel de significación del 2.5%, si hay evidencia suficiente para concluir que, la proporción de vuelos en los que algún pasajero se quede sin asiento es mayor a 0.60. Realice sus conclusiones usando el p-valor.
- (2.0 puntos) Considere que en el futuro se desea repetir este estudio. En este caso, se tiene como objetivos estimar la proporción de vuelos donde ningún pasajero se queda sin asiento con un margen de error no mayor de 0.04 a un nivel de confianza del 98% y estimar la media del número de pasajero que se presentan a un vuelo con un margen de error de 0.25 pasajeros a un nivel de confianza del 99%. ¿Qué tamaño de muestra recomendaría para cumplir con los objetivos de este nuevo estudio? Considere la información presentada como una muestra piloto de este futuro estudio.

Solución

Parte a)

Como la población no es normal, la varianza poblacional es desconocida y el tamaño de muestra es suficientemente grande, usaremos

$$IC_{99\%}(\mu) = \left[\bar{x} - t_{0.995,100} \frac{s}{\sqrt{n}}, \bar{x} + t_{0.995,100} \frac{s}{\sqrt{n}} \right]$$

reemplazando

$$IC_{99\%}(\mu) = \left[201.2970297 - 2.626 \times \frac{2.8908911}{\sqrt{101}}, 201.2970297 + 2.626 \times \frac{2.8908911}{\sqrt{101}} \right] = [200.542, 202.052]$$

Con un nivel de confianza del 99% podemos afirmar que la media del número de pasajeros que se presenta a su vuelo está entre 200.542 y 202.052.

Parte b)

Sea p =proporción de vuelos con pasajeros que se quedan sin asientos. Entonces, las hipótesis son

$$\begin{aligned} H_0 : p &= 0.6 \\ H_1 : p &> 0.6 \end{aligned}$$

Nivel de significación: $\alpha = 0.025$. Como el tamaño de muestra es suficientemente grande, utilizaremos como estadística de prueba

$$Z = \frac{\bar{p} - p_0}{\sqrt{p_0(1 - p_0)/101}} \stackrel{approx}{\sim} N(0, 1), \text{ si } H_0 \text{ es verdadera.}$$

Se obtiene $Z_{obs} = \frac{0.6435644 - 0.6}{\sqrt{0.6(1 - 0.6)/101}} = 1.82$. Calculamos p-valor = $P(Z > 1.82) = 0.0344$ Como no se cumple que p-valor < 0.025 , no se rechaza H_0 .

Con un nivel de significación del 2.5% se puede decir que no existe suficiente evidencia para afirmar que la proporción de vuelos con pasajeros que se quedan sin asientos es mayor a 0.6.

Parte c)

Primero hallamos el tamaño de muestra para estimar la proporción

$$n = \frac{z_{0.99}^2 \bar{p}(1 - \bar{p})}{e^2} = \frac{2.326^2 \times 0.6435644(1 - 0.6435644)}{0.04^2} = 775.66 \approx 776.$$

Luego, hallamos el tamaño de muestra para estimar la media

$$n = \frac{z_{0.995}^2 \sigma^2}{e^2} = \frac{2.576^2 \times 2.8908911^2}{0.25^2} = 887.31 \approx 888.$$

Por lo tanto, se recomendaría tomar un tamaño de muestra de $n = 888$ para cumplir con los dos objetivos del estudio.

Pregunta 4 (5.0 puntos)

La base de datos **Prestige** contiene información del nivel de prestigio (**prestige**) de 102 ocupaciones en un País, así como estadísticas del número promedio de años de estudios de sus trabajadores (**education**), de su ingreso promedio anual en miles de dólares (**income**) y del porcentaje de mujeres que trabajan en esa ocupación (**women**). El nivel de prestigio es un índice que indica que a mayor puntaje la ocupación tendrá un mayor prestigio.

- a) Al hacer una análisis de regresión lineal simple, tomando como variable dependiente el prestigio y como variable independiente la educación se obtuvo la siguiente salida

```
M1 = lm(prestige~education,data=Prestige)
summary(M1)

## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -10.73      3.68    -2.92  0.00216 **
## education      5.36      0.33    16.24 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.1 on 100 degrees of freedom
## Multiple R-squared:  0.7228, Adjusted R-squared:  0.72
## F-statistic: 260.8 on 1 and 100 DF, p-value: < 2.2e-16

# Estadísticas - Educación
descr(Prestige$education,stats=c("n.valid","mean","sd"))

## Descriptive Statistics
## Prestige$education
## N: 102
##
##              education
## -----
##      N.Valid      102.00
##      Mean        10.74
##      Std.Dev       2.73
```

```
# Cuantiles t-Student
qt(c(0.90,0.95,0.975,0.99),100)
```

```
## [1] 1.290 1.660 1.984 2.364
```

Si para una cierta ocupación, el número de años de estudios promedio es de 14 años ¿en cuánto estima sea el nivel de prestigio medio de esta ocupación? Calcule también para tal nivel un intervalo de confianza al 95%.

- b) Si en un medio local se indica que por cada año adicional que en promedio se estudie una ocupación, el prestigio de esta se incrementa en promedio en más de 4 años y medio, ¿muestran los datos, a un nivel de significación de $\alpha = 0.05$, que el medio tiene razón?
- c) Con el propósito de usar las demás covariables, un investigador plantea un modelo de regresión lineal múltiple para el nivel de prestigio medio, con todas las variables en la base de datos; mientras que otro investigador piensa que bastaría solo considerar la educación y el ingreso como variables independientes. Daría la razón a alguno de ellos o a lo mejor a ninguno, en el sentido que un modelo más sencillo y de mejor ajuste sería el simple dado en a)?

```
M2 = lm(prestige~education+income+women,data=Prestige)
summary(M2)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -6.79      3.24    -2.10  0.0191 *
## education      4.19      0.39    10.74 < 2e-16 ***
## income         1.31      0.28     4.68  4.6e-06 ***
## women         -0.01      0.03    -0.33  0.3711
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.85 on 98 degrees of freedom
## Multiple R-squared:  0.7982, Adjusted R-squared:  0.792
## F-statistic: 129.2 on 3 and 98 DF, p-value: < 2.2e-16
```

```
M3 = lm(prestige~education+income,data=Prestige)
summary(M3)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -6.85      3.22    -2.13  0.0178 *
## education      4.14      0.35    11.83 < 2e-16 ***
## income         1.36      0.22     6.18 7.17e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.81 on 99 degrees of freedom
## Multiple R-squared:  0.798, Adjusted R-squared:  0.7939
## F-statistic: 195.6 on 2 and 99 DF, p-value: < 2.2e-16
```

- d) En base a la salida anterior, estime en cuanto y cómo variaría el prestigio medio de una ocupación, por cada año adicional de estudio que esta tenga y por un incremento de 200 dólares en sus ingresos promedios anuales.

Solución

Parte a)

La ocupación se espera tenga un nivel de prestigio medio de

$$\hat{y}_{14} = -10.73 + 5.36 \times 14 = 64.31$$

El IC al 95% para y_{14} será:

$$[\hat{y}_{14} - t_{0.975}(100) \times \hat{EE}(\hat{y}_{14}) \quad , \quad \hat{y}_{14} + t_{0.975}(100) \times \hat{EE}(\hat{y}_{14})]$$

donde $\hat{EE}(\hat{y}_{14}) = 9.1 \sqrt{\frac{1}{102} + \frac{(14-10.74)^2}{(102-1) \times 2.73^2}} = 1.4074856$. Luego el IC es

$$[64.31 - 1.984 \times 1.4074856, 64.31 + 1.984 \times 1.4074856] = [61.5175486 \quad , \quad 67.1024514].$$

Parte b)

Si β_1 denota al cambio esperado en el prestigio por año adicional de estudio, se desea contrastar a nivel $\alpha = 0.05$:

$$H_0 : \beta_1 = 4.5 \quad \text{vs} \quad H_1 : \beta_1 > 4.5$$

y se rechazará H_0 si $T_0 = \frac{\hat{\beta}_1 - 4}{\hat{EE}(\hat{\beta}_1)} > t_{0.95}(100) = 1.66$. Evaluando T_0 , obtenemos que

$$T_0 = \frac{5.36 - 4.50}{0.33} = 2.61$$

y por tanto, se rechaza H_0 ; es decir, si se puede decir que el medio tiene razón.

Parte c)

El mejor modelo será el del segundo investigador que ajusta el prestigio solo con las variables de educación e ingreso, pues es el que tiene un mayor R^2 ajustado.

Parte d)

Se pide evaluar el estimador $\hat{\beta}_1 + 0.2\hat{\beta}_2$ y su valor observado es

$$4.14 + 0.2 \times 1.36 = 4.412,$$

es decir, el prestigio medio de esta ocupación se espera se incremente en 4.412 puntos.