

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA



Parte dirigida

Curso : Probabilidad y Estadística

Horario : 0681

Profesor : Valdivieso

Práctica : 02

Nombres y códigos :

20202098 - John Arzapalo

20221548 - Ricardo Valentino Lara Figueroa

20223796 - Luis Miranda

Parte a:

Captura de la salida en RStudio mostrando el número de fallas simuladas para cada una de las 12 máquinas durante 60 días. Se observa el total de fallas acumuladas, el promedio por máquina y la comparación con el valor esperado teórico, evidenciando que el resultado de la simulación es consistente con el modelo de Poisson.

Metodología utilizada:

- Tasa de fallas: $\lambda = 2$ fallas/mes = 0.0667 fallas/día
- Para cada máquina: Genero tiempos entre fallas exponenciales hasta superar los 60 días
- Conteo: Cuento cuántas fallas ocurren dentro del intervalo [0, 60) días

```
Console Terminal Background Jobs
R 4.4.3 ~ /
> # =====
> # PRÁCTICA CALIFICADA 2 - PARTE 2
> # Análisis de fallas de máquinas y utilidades empresariales
> # =====
>
> # Configuración inicial
> set.seed(123) # Para reproducibilidad de resultados
>
> # Parámetros del problema
> lambda <- 2/30 # Tasa de fallas por día (2 fallas por mes de 30 días)
> cat("Parámetros del problema:\n")
Parámetros del problema:
> cat(sprintf("- Tasa de fallas: %.4f fallas por día\n", lambda))
- Tasa de fallas: 0.0667 fallas por día
> cat(sprintf("- Equivalente a: %.2f fallas por mes\n\n", lambda * 30))
- Equivalente a: 2.00 fallas por mes
>
> # =====
> # PARTE A: Simulación de fallas sin usar rpois
> # =====
>
> cat("=== PARTE A ===\n")
=== PARTE A ===
> cat("Simulación de proceso de Poisson sin usar rpois()\n")
Simulación de proceso de Poisson sin usar rpois()
> cat("12 máquinas por 2 meses (60 días)\n\n")
12 máquinas por 2 meses (60 días)
>
> # Función para simular proceso de Poisson sin usar rpois
> # Método: generar tiempos de eventos exponenciales y contar eventos en [0,t)
> simular_poisson <- function(lambda, t) {
+   eventos <- 0
+   tiempo_actual <- 0
+
+   while(TRUE) {
+     # Generar tiempo entre eventos (exponencial con parámetro lambda)
+     # Método de transformación inversa: T = -ln(U)/λ donde U~Uniform(0,1)
+     tiempo_entre_eventos <- -log(runif(1)) / lambda
+     tiempo_actual <- tiempo_actual + tiempo_entre_eventos
```

```

+     # Solo contar si el evento ocurre ANTES de t (intervalo [0,t))
+     if(tiempo_actual < t) {
+         eventos <- eventos + 1
+     } else {
+         break # Salir del bucle cuando se excede el tiempo t
+     }
+ }
+
+ return(eventos)
+ }
>
> # Parámetros para parte A
> n_maquinas_a <- 12
> tiempo_a <- 60 # días (2 meses)
>
> # Simulación para cada máquina
> fallas_por_maquina <- numeric(n_maquinas_a)
> cat("Resultados por máquina:\n")
Resultados por máquina:
> for(i in 1:n_maquinas_a) {
+   fallas_por_maquina[i] <- simular_poisson(lambda, tiempo_a)
+   cat(sprintf("Máquina %2d: %d fallas\n", i, fallas_por_maquina[i]))
+ }
Máquina 1: 5 fallas
Máquina 2: 8 fallas
Máquina 3: 2 fallas
Máquina 4: 10 fallas
Máquina 5: 5 fallas
Máquina 6: 4 fallas
Máquina 7: 3 fallas
Máquina 8: 2 fallas
Máquina 9: 3 fallas
Máquina 10: 4 fallas
Máquina 11: 5 fallas
Máquina 12: 7 fallas
>
> # Estadísticas resumidas
> fallas_totales <- sum(fallas_por_maquina)
> promedio_por_maquina <- mean(fallas_por_maquina)
> valor_esperado_teorico <- lambda * tiempo_a * n_maquinas_a
>

> cat(sprintf("\n--- RESUMEN PARTE A ---\n"))

--- RESUMEN PARTE A ---
> cat(sprintf("Total de fallas simuladas: %d\n", fallas_totales))
Total de fallas simuladas: 58
> cat(sprintf("Promedio por máquina: %.2f fallas\n", promedio_por_maquina))
Promedio por máquina: 4.83 fallas
> cat(sprintf("Valor esperado teórico total: %.2f fallas\n", valor_esperado_teorico))
Valor esperado teórico total: 48.00 fallas
> cat(sprintf("Diferencia con esperado: %+2f fallas\n", fallas_totales - valor_esperado_teorico))
Diferencia con esperado: +10.00 fallas
> |

```

Environment

El Environment en esta etapa muestra únicamente los parámetros iniciales (lambda, n_maquinas_a, tiempo_a) y el vector fallas_por_maquina con las fallas de cada una de las 12 máquinas. Es un entorno todavía sencillo, ya que esta primera parte se enfoca en la simulación básica de un proceso de Poisson. Esto marca el punto de partida de la práctica, estableciendo la base sobre la cual se construirán las siguientes simulaciones.


```
Console Terminal x Background Jobs x
R 4.4.3 · ~/
> # =====
> # PARTE B: Cálculo de utilidad y cuantil 0.75 para t=30 días
> # =====
>
> cat("\n=== PARTE B ===\n")

=== PARTE B ===
> cat("Modelo de negocio y cálculo de utilidades\n")
Modelo de negocio y cálculo de utilidades
> cat("Parámetros económicos:\n")
Parámetros económicos:
> cat("- Precio de alquiler a minera: 150 soles/día\n")
- Precio de alquiler a minera: 150 soles/día
> cat("- Costo de renta al fabricante: 60 soles/día\n")
- Costo de renta al fabricante: 60 soles/día
> cat("- Costo de máquina de reemplazo: 100 soles/día\n")
- Costo de máquina de reemplazo: 100 soles/día

>
> # Función para simular el tiempo de la primera falla (distribución exponencial)
> simular_tiempo_primera_falla <- function(lambda) {
+   return(-log(runif(1)) / lambda)
+ }
>
> # Función para calcular utilidad de UNA máquina
> calcular_utilidad_una_maquina <- function(t) {
+   # Modelo de ingresos y costos
+   ingresos <- 150 * t           # 150 soles por día durante t días
+   costo_base <- 60 * t          # 60t soles pagados al fabricante
+
+   # Simular tiempo hasta primera falla de la máquina original
+   tiempo_falla_original <- simular_tiempo_primera_falla(lambda)
+
+   if(tiempo_falla_original <= t) {
+     # La máquina original falla dentro del período de contrato
+     dias_restantes <- t - tiempo_falla_original
+
+     # Costo adicional: 100 soles por día por la máquina de reemplazo
+     # Se paga por todos los días restantes del contrato
+     costo_adicional <- 100 * dias_restantes
+   }
```

```

+   utilidad <- ingresos - costo_base - costo_adicional
+ } else {
+   # No hay falla de la máquina original durante el contrato
+   utilidad <- ingresos - costo_base # = 90*t
+ }
+
+   return(utilidad)
+ }
>
> # Simulación para t=30 días
> t_b <- 30
> n_sim_b <- 10000
> cat(sprintf("Simulando %d utilidades para t=%d días...\n", n_sim_b, t_b))
Simulando 10000 utilidades para t=30 días...
>
> utilidades_30 <- replicate(n_sim_b, calcular_utilidad_una_maquina(t_b))
>
> # Cálculo del cuantil 0.75
> cuantil_75 <- quantile(utilidades_30, 0.75)
> promedio_b <- mean(utilidades_30)
> desviacion_b <- sd(utilidades_30)
>
> cat(sprintf("\n--- RESULTADOS PARTE B ---\n"))

--- RESULTADOS PARTE B ---
> cat(sprintf("Para t = %d días (una máquina):\n", t_b))
Para t = 30 días (una máquina):
> cat(sprintf("Cuantil 0.75 de la utilidad: %.2f soles\n", cuantil_75))
Cuantil 0.75 de la utilidad: 1763.61 soles
> cat(sprintf("Utilidad promedio: %.2f soles\n", promedio_b))
Utilidad promedio: 1003.02 soles
> cat(sprintf("Desviación estándar: %.2f soles\n", desviacion_b))
Desviación estándar: 990.74 soles
> cat(sprintf("Utilidad mínima: %.2f soles\n", min(utilidades_30)))
Utilidad mínima: -299.91 soles
> cat(sprintf("Utilidad máxima: %.2f soles\n", max(utilidades_30)))
Utilidad máxima: 2700.00 soles
>

> # Análisis adicional
> prob_sin_falla <- exp(-lambda * t_b)
> utilidad_sin_falla <- 90 * t_b
> cat(sprintf("\nAnálisis teórico:\n"))

Análisis teórico:
> cat(sprintf("P(sin falla en %d días): %.3f\n", t_b, prob_sin_falla))
P(sin falla en 30 días): 0.135
> cat(sprintf("Utilidad si no hay falla: %.0f soles\n", utilidad_sin_falla))
Utilidad si no hay falla: 2700 soles
> |

```

Interpretación del cuantil 0.75:


- 1,763.61 soles representa el valor que supera el 75% de las utilidades simuladas
- Esto significa que en 3 de cada 4 contratos, la empresa obtendrá al menos esta utilidad
- Es un umbral de seguridad para la planificación financiera

Distribución de resultados:

- Mejor escenario: 2,700 soles (sin fallas, probabilidad $\approx 13.5\%$)
- Peor escenario: -299.91 soles (falla muy temprana)
- Variabilidad alta: Desviación estándar de 990.74 soles indica riesgo significativo

Environment

Aquí el Environment empieza a crecer al incluir los resultados de las 10,000 simulaciones de utilidad (utilidades_30) y las métricas estadísticas (cuantil_75, promedio_b, desviacion_b). Esto refleja un análisis más profundo: ya no solo se cuentan fallas, sino que se cuantifica el impacto económico de los eventos. La extensión del Environment en esta parte es evidencia del aumento en la complejidad del problema y de la cantidad de información relevante que se genera para el análisis.



The screenshot shows the RStudio Environment pane for a 'Global Environment'. It lists various variables and functions. The 'Values' section contains a table of variables, and the 'Functions' section contains a table of functions.

Values	
cuantil_75	Named num 1764
desviacion_b	990.740647610219
fallas_por_maquina	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...
fallas_totales	58
i	12L
lambda	0.0666666666666667
n_maquinas_a	12
n_sim_b	10000
prob_sin_falla	0.135335283236613
promedio_b	1003.02468122554
promedio_por_maquina	4.83333333333333
t_b	30
tiempo_a	60
utilidad_sin_falla	2700
utilidades_30	num [1:10000] 123 395 213 2700 816 ...
valor_esperado_teor...	48

Functions	
calcular_utilidad_un...	function (t)
simular_poisson	function (lambda, t)
simular_tiempo_prime...	function (lambda)

Validación teórica:

prob_sin_falla **0.135335283236613**

Podemos observar que el valor teórico de la probabilidad de que no se tengan fallas por 30 días es 0.1353352832, esto valida nuestros resultados de simulación, donde aproximadamente el 13.5% de los contratos alcanzan la utilidad máxima.

Conclusión:

El cuantil 0.75 de 1,763.61 soles proporciona una métrica robusta para la toma de decisiones. Indica que la empresa puede esperar con alta confianza (75%) obtener al menos esta utilidad en contratos individuales de 30 días. La significativa desviación estándar refleja el riesgo inherente del negocio, donde fallas tempranas pueden reducir considerablemente la rentabilidad, pero en la mayoría de los casos se mantienen utilidades positivas sustanciales.

Parte c:

Gráfico de la utilidad esperada en función de la duración del contrato (t). La curva muestra un máximo claro alrededor de $t = [\text{valor encontrado}]$ días, que es resaltado

con una línea vertical y un punto rojo. Esta visualización confirma el valor óptimo de t que maximiza la utilidad esperada de la empresa.

```
Console Terminal Background Jobs
R 4.4.3 · ~/
> # =====
> # PARTE C: Valor óptimo de t que maximiza utilidad esperada
> # =====
> cat("\n=== PARTE C ===\n")

=== PARTE C ===
> cat("Búsqueda del valor óptimo de t (días enteros)\n\n")
Búsqueda del valor óptimo de t (días enteros)

>
> # Función para calcular utilidad esperada teóricamente (más eficiente y precisa)
> calcular_utilidad_esperada_teorica <- function(t) {
+   # P(no falla en [0,t]) = exp(-λt)
+   prob_no_falla <- exp(-lambda * t)
+   +
+   # Utilidad si no hay falla durante el contrato
+   utilidad_sin_falla <- 150 * t - 60 * t # = 90*t
+   +
+   # Si hay falla, el tiempo esperado de falla dado que falla en [0,t] es:
+   # E[T | T ≤ t] = (1 - (1 + λt)e^(-λt)) / (λ(1 - e^(-λt)))
+   if(lambda * t < 1e-10) {
+     # Para λt muy pequeño, usar aproximación de Taylor
+     tiempo_falla_esperado <- t / 2
+   } else {
+     numerador <- 1 - (1 + lambda * t) * exp(-lambda * t)
+     denominador <- lambda * (1 - exp(-lambda * t))
+     tiempo_falla_esperado <- numerador / denominador
+   }
+   +
+   # Utilidad esperada si hay falla
+   dias_restantes_esperados <- t - tiempo_falla_esperado
+   utilidad_con_falla <- 150 * t - 60 * t - 100 * dias_restantes_esperados
+   +
+   # Utilidad esperada total usando ley de expectativa total
+   utilidad_esperada <- prob_no_falla * utilidad_sin_falla + (1 - prob_no_falla) * utilidad_con_falla
+   +
+   return(utilidad_esperada)
+ }
```



```

> # Búsqueda del t óptimo (días enteros)
> t_values <- 1:200 # Rango amplio de búsqueda
> cat("Calculando utilidad esperada teórica...\n")
Calculando utilidad esperada teórica...
> utilidades_esperadas <- sapply(t_values, calcular_utilidad_esperada_teorica)
>
> # Encontrar el óptimo
> t_optimo <- t_values[which.max(utilidades_esperadas)]
> utilidad_maxima <- max(utilidades_esperadas)
>
> cat(sprintf("\n--- RESULTADOS PARTE C ---\n"))


--- RESULTADOS PARTE C ---
> cat(sprintf("Valor óptimo de t: %d días\n", t_optimo))
Valor óptimo de t: 35 días
> cat(sprintf("Utilidad esperada máxima: %.2f soles\n", utilidad_maxima))
Utilidad esperada máxima: 1004.54 soles
>
> # Mostrar valores alrededor del óptimo para verificación
> idx_optimo <- which.max(utilidades_esperadas)
> rango_analisis <- max(1, idx_optimo-3):min(length(t_values), idx_optimo+3)
> cat(sprintf("\nUtilidades esperadas cerca del óptimo:\n"))

Utilidades esperadas cerca del óptimo:
> for(i in rango_analisis) {
+   marca <- if(i == idx_optimo) " <-- ÓPTIMO" else ""
+   cat(sprintf("t = %3d días: %.2f soles%s\n", t_values[i], utilidades_esperadas[i], marca))
+ }
t = 32 días: 1002.34 soles
t = 33 días: 1003.80 soles
t = 34 días: 1004.51 soles
t = 35 días: 1004.54 soles <-- ÓPTIMO
t = 36 días: 1003.92 soles
t = 37 días: 1002.70 soles
t = 38 días: 1000.91 soles
>

>
> # Crear gráfico de utilidad esperada vs t
> plot(t_values[1:100], utilidades_esperadas[1:100],
+      type="l", col="blue", lwd=2,
+      xlab="Días de contrato (t)",
+      ylab="Utilidad esperada (soles)",
+      main="Utilidad Esperada vs Duración del Contrato")
> abline(v=t_optimo, col="red", lty=2, lwd=2)
> points(t_optimo, utilidad_maxima, col="red", pch=19, cex=1.5)
> text(t_optimo+8, utilidad_maxima-30,
+      paste("t* =", t_optimo, "días\nU* =", round(utilidad_maxima,1), "soles"),
+      col="red", cex=0.9)
> grid(col="gray", lty=3)
> |

```

Gráfico de la utilidad esperada en función de la duración del contrato (t). La curva azul muestra cómo la utilidad aumenta con t hasta alcanzar un máximo, después del cual comienza a decrecer. La línea roja punteada y el punto resaltado indican el valor óptimo de t, donde se logra la utilidad máxima. Este gráfico facilita identificar visualmente la duración del contrato que maximiza la rentabilidad.



Interpretación Económica del Óptimo:

Balance riesgo-beneficio: A los 35 días se maximiza el trade-off entre:

- Ingresos por alquiler crecientes con t
- Costos esperados por fallas que aumentan con t

Probabilidades clave:

- $P(\text{falla en 35 días}) = 1 - e^{(-0.0667 \times 35)} \approx 90.3\%$
- $P(\text{sin falla}) \approx 9.7\%$

El 35 días representa el punto donde el ingreso marginal iguala al costo marginal esperado

Rentabilidad comparativa:

Contrato óptimo (35 días): 1,004.54 soles

- Contrato de 30 días: $\approx 1,003$ soles (0.15% menos)
- Contrato de 40 días: $\approx 1,000$ soles (0.45% menos)

Environment

En esta fase el Environment se expande aún más, ya que se generan vectores largos como `utilidades_esperadas`, que almacena la utilidad esperada para más de 200 posibles valores de `t`. También aparecen objetos clave como `t_optimo` y `utilidad_maxima`, que permiten identificar el punto de máxima rentabilidad. Esta evolución del entorno refleja el paso de simulaciones aleatorias a un análisis sistemático y exhaustivo del problema.

Environment	History	Connections	Tutorial
R Global Environment			
Values			
<code>cuantil_75</code>	Named num 1764		
<code>desviacion_b</code>	990.740647610219		
<code>fallas_por_maquina</code>	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...		
<code>fallas_totales</code>	58		
<code>i</code>	38L		
<code>idx_optimo</code>	35L		
<code>lambda</code>	0.06666666666666667		
<code>marca</code>	""		
<code>n_maquinas_a</code>	12		
<code>n_sim_b</code>	10000		
<code>prob_sin_falla</code>	0.135335283236613		
<code>promedio_b</code>	1003.02468122554		
<code>promedio_por_maquina</code>	4.833333333333333		
<code>rango_analisis</code>	int [1:7] 32 33 34 35 36 37 38		
<code>t_b</code>	30		
<code>t_optimo</code>	35L		
<code>t_values</code>	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...		
<code>tiempo_a</code>	60		
<code>utilidad_maxima</code>	1004.54204820339		
<code>utilidad_sin_falla</code>	2700		
<code>utilidades_30</code>	num [1:10000] 123 395 213 2700 816 ...		
<code>utilidades_esperadas</code>	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...		
<code>valor_esperado_teori...</code>	48		
Functions			
<code>calcular_utilidad_es...</code>	function (t)		
<code>calcular_utilidad_un...</code>	function (t)		
<code>simular_poisson</code>	function (lambda, t)		
<code>simular_tiempo_prime...</code>	function (lambda)		

Conclusión:

El análisis determinó que el valor de `t` que maximiza la utilidad esperada se encuentra alrededor de `t = [t_optimo]` días. Este resultado permite definir la duración óptima de los contratos para maximizar la rentabilidad de la empresa en el largo plazo. La solución es robusta y representa el balance entre la maximización de ingresos y la gestión del riesgo de fallas.

Parte d:

Histograma de las utilidades simuladas para el alquiler de 20 máquinas durante 30 días en 10,000 experimentos. La línea roja indica la media y la línea naranja la

mediana. Se aprecia que la distribución es aproximadamente simétrica, lo que valida que el promedio y la mediana estén cercanos.

```
Console Terminal Background Jobs
R 4.4.3 · ~/
> # =====
> # PARTE D: Simulación para 20 máquinas con distribución Poisson
> # =====
> cat("\n=== PARTE D ===\n")

=== PARTE D ===
> cat("Simulación de utilidades para múltiples máquinas\n")
Simulación de utilidades para múltiples máquinas
> cat("20 máquinas, t=30 días, 10,000 simulaciones\n\n")
20 máquinas, t=30 días, 10,000 simulaciones

>
> # Función para calcular utilidad total de múltiples máquinas
> calcular_utilidad_total <- function(n_maquinas, t) {
+   utilidad_total <- 0
+   for(i in 1:n_maquinas) {
+     utilidad_total <- utilidad_total + calcular_utilidad_una_maquina(t)
+   }
+   return(utilidad_total)
+ }
>
> # Parámetros para parte D
> n_maquinas_d <- 20
> t_d <- 30
> n_sim_d <- 10000
>
> cat(sprintf("Realizando %d simulaciones...\n", n_sim_d))
Realizando 10000 simulaciones...
> cat("Cada simulación representa el alquiler simultáneo de 20 máquinas\n")
Cada simulación representa el alquiler simultáneo de 20 máquinas
>
> # Realizar simulaciones
> utilidades_20_maquinas <- replicate(n_sim_d, calcular_utilidad_total(n_maquinas_d, t_d))
>
> # Estadísticas descriptivas
> promedio_d <- mean(utilidades_20_maquinas)
> desv_std_d <- sd(utilidades_20_maquinas)
> mediana_d <- median(utilidades_20_maquinas)
> min_d <- min(utilidades_20_maquinas)
> max_d <- max(utilidades_20_maquinas)
>
```

```

> cat(sprintf("\n--- RESULTADOS PARTE D ---\n"))

--- RESULTADOS PARTE D ---
> cat(sprintf("Distribución Poisson - 20 máquinas, t=30 días:\n"))
Distribución Poisson - 20 máquinas, t=30 días:
> cat(sprintf("Promedio de utilidades: %10.2f soles\n", promedio_d))
Promedio de utilidades: 19954.94 soles
> cat(sprintf("Desviación estándar: %10.2f soles\n", desv_std_d))
Desviación estándar: 4460.26 soles
> cat(sprintf("Mediana: %10.2f soles\n", mediana_d))
Mediana: 19872.15 soles
> cat(sprintf("Mínimo: %10.2f soles\n", min_d))
Mínimo: 4932.67 soles
> cat(sprintf("Máximo: %10.2f soles\n", max_d))
Máximo: 36725.46 soles
>
> # Cuantiles adicionales
> cuantiles_d <- quantile(utilidades_20_maquinas, c(0.25, 0.5, 0.75, 0.9, 0.95))
> cat(sprintf("\nCuantiles de la distribución:\n"))


Cuantiles de la distribución:
> cat(sprintf("Q25: %8.2f soles\n", cuantiles_d[1]))
Q25: 16850.79 soles
> cat(sprintf("Q50: %8.2f soles\n", cuantiles_d[2]))
Q50: 19872.15 soles
> cat(sprintf("Q75: %8.2f soles\n", cuantiles_d[3]))
Q75: 22983.33 soles
> cat(sprintf("Q90: %8.2f soles\n", cuantiles_d[4]))
Q90: 25710.20 soles
> cat(sprintf("Q95: %8.2f soles\n", cuantiles_d[5]))
Q95: 27477.02 soles
>

> # Histograma de resultados
> hist(utilidades_20_maquinas, breaks=50,
+      col="lightblue", border="darkblue",
+      main="Distribución de Utilidades (20 máquinas, 30 días, Poisson)",
+      xlab="Utilidad total (soles)",
+      ylab="Frecuencia")
> abline(v=promedio_d, col="red", lwd=3)
> abline(v=mediana_d, col="orange", lwd=2, lty=2)
> legend("topright",
+      c("Media", "Mediana"),
+      col=c("red", "orange"),
+      lwd=c(3,2), lty=c(1,2))
> |

```

Histograma de las utilidades simuladas para el alquiler de 20 máquinas durante 30 días en 10,000 simulaciones. La distribución se observa aproximadamente simétrica, con una concentración de valores en torno a la media (línea roja) y la mediana (línea naranja punteada). Esta visualización permite apreciar la dispersión de las utilidades y confirmar que no existen valores atípicos extremos.

Distribución de Utilidades (20 máquinas, 30 días, Poisson)



Environment

El Environment se vuelve considerablemente más extenso debido a la inclusión de `utilidades_20_maquinas`, un vector de 10,000 valores que representa los escenarios de simulación para 20 máquinas. Se agregan además estadísticas descriptivas (media, desviación, cuantiles), lo que transforma el entorno en un repositorio de información masiva. Este crecimiento es esperado, ya que se incrementa el número de máquinas y el volumen de datos simulados, proporcionando una visión más realista de la variabilidad de utilidades.

Environment	History	Connections	Tutorial
Import Dataset	128 MiB	List	
R	Global Environment		
Values			
cuantil_75	Named num 1764		
cuantiles_d	Named num [1:5] 16851 19872 22983 25710 27477		
desv_std_d	4460.26281148556		
desviacion_b	990.740647610219		
fallas_por_maquina	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...		
fallas_totales	58		
i	38L		
idx_optimo	35L		
lambda	0.06666666666666667		
marca	""		
max_d	36725.4622821585		
mediana_d	19872.1526007883		
min_d	4932.67022290296		
n_maquinas_a	12		
n_maquinas_d	20		
n_sim_b	10000		
n_sim_d	10000		
prob_sin_falla	0.135335283236613		
promedio_b	1003.02468122554		
promedio_d	19954.9374548353		
promedio_por_maquina	4.833333333333333		
rango_analisis	int [1:7] 32 33 34 35 36 37 38		
t_b	30		
t_d	30		
t_optimo	35L		
t_values	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...		
tiempo_a	60		
utilidad_maxima	1004.54204820339		
utilidad_sin_falla	2700		
utilidades_20_maquin...	num [1:10000] 12852 19805 12572 21180 13360 ...		
utilidades_30	num [1:10000] 123 395 213 2700 816 ...		
utilidades_esperadas	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...		
valor_esperado_teori...	48		

Functions	
calcular_utilidad_es...	function (t)
calcular_utilidad_to...	function (n_maquinas, t)
calcular_utilidad_un...	function (t)
simular_poisson	function (lambda, t)
simular_tiempo_prime...	function (lambda)

Conclusión:

La simulación de 10,000 escenarios con 20 máquinas permitió estimar de forma robusta la distribución de utilidades. Los resultados muestran que la utilidad promedio es consistente con el valor esperado teórico y la variabilidad es moderada, lo que brinda confianza en la estabilidad de las ganancias en contratos múltiples.

Parte e:

Resultados de la simulación usando la nueva distribución de tiempos de falla. Se compara el cuantil 0.75 de la utilidad y el valor de t óptimo frente al modelo de Poisson, concluyendo si existe un cambio significativo. Se incluye un análisis comparativo de medias y desviaciones estándar de ambas distribuciones de tiempos de falla.

```
Console Terminal Background Jobs
R 4.4.3 ~ /

> # =====
> # PARTE E: Nueva distribución para tiempo hasta primera falla
> # =====
>
> cat("\n=== PARTE E ===\n")

=== PARTE E ===
> cat("Implementación de nueva distribución de tiempo de falla\n")
Implementación de nueva distribución de tiempo de falla
> cat("f(t) = (8t/225) * exp(-4t²/225) para t > 0\n\n")
f(t) = (8t/225) * exp(-4t²/225) para t > 0

>
> # Función de densidad de la nueva distribución
> densidad_nueva <- function(t) {
+   if(t <= 0) return(0)
+   return((8 * t / 225) * exp(-4 * t² / 225))
+ }
>
> # Encontrar el máximo de la función de densidad para el método de rechazo
> # f'(t) = (8/225) * e-4t²/225 * [1 - (8t²/225)]
> # f'(t) = 0 cuando 1 - (8t²/225) = 0, es decir t = sqrt(225/8)
> t_max_densidad <- sqrt(225/8)
> f_max <- densidad_nueva(t_max_densidad)
>
> cat(sprintf("Análisis de la nueva distribución:\n"))
Análisis de la nueva distribución:
> cat(sprintf("Máximo de la densidad en t = %.3f días\n", t_max_densidad))
Máximo de la densidad en t = 5.303 días
> cat(sprintf("Valor máximo f(t*) = %.6f\n", f_max))
Valor máximo f(t*) = 0.114369
>
```



```

> # Implementación del método de rechazo para generar muestras
> generar_tiempo_nueva_distribucion <- function() {
+   # Método de rechazo con dominio amplio para capturar la cola
+   max_t <- 50 # Dominio suficiente ya que la función decrece rápidamente
+
+   repeat {
+     # Generar candidato uniformemente
+     t_candidato <- runif(1, 0, max_t)
+     u <- runif(1, 0, f_max * 1.05) # Pequeño margen de seguridad
+
+     # Evaluar función de densidad
+     f_t <- densidad_nueva(t_candidato)
+
+     # Aceptar o rechazar
+     if(u <= f_t) {
+       return(t_candidato)
+     }
+   }
+ }
>
> # Función para calcular utilidad con la nueva distribución
> calcular_utilidad_nueva_dist <- function(t) {
+   # Mismo modelo de costos que antes
+   ingresos <- 150 * t
+   costo_base <- 60 * t
+
+   # Generar tiempo hasta primera falla con la nueva distribución
+   tiempo_falla <- generar_tiempo_nueva_distribucion()
+
+   if(tiempo_falla <= t) {
+     # Hay falla dentro del período de contrato
+     dias_restantes <- t - tiempo_falla
+     costo_adicional <- 100 * dias_restantes
+     utilidad <- ingresos - costo_base - costo_adicional
+   } else {
+     # No hay falla durante el contrato
+     utilidad <- ingresos - costo_base
+   }
+
+   return(utilidad)
+ }

```

```

> # Recalcular cuantil 0.75 para t=30 con la nueva distribución
> n_sim_e <- 10000
> cat(sprintf("Calculando cuantil 0.75 con nueva distribución (%d simulaciones)...\n", n_sim_e))
Calculando cuantil 0.75 con nueva distribución (10000 simulaciones)...
> utilidades_30_nueva <- replicate(n_sim_e, calcular_utilidad_nueva_dist(30))
> cuantil_75_nueva <- quantile(utilidades_30_nueva, 0.75)
>
> # Búsqueda del nuevo t óptimo (búsqueda más limitada por eficiencia)
> utilidad_esperada_nueva <- function(t, n_sim = 1000) {
+   utilidades <- replicate(n_sim, calcular_utilidad_nueva_dist(t))
+   return(mean(utilidades))
+ }
>
> t_valores_nueva <- seq(10, 100, by=5) # Búsqueda más espaciada
> cat("Buscando t óptimo con nueva distribución...\n")
Buscando t óptimo con nueva distribución...
> utilidades_nueva_dist <- numeric(length(t_valores_nueva))
>
> for(i in seq_along(t_valores_nueva)) {
+   utilidades_nueva_dist[i] <- utilidad_esperada_nueva(t_valores_nueva[i])
+   cat(sprintf("t = %3d días: %8.2f soles\n", t_valores_nueva[i], utilidades_nueva_dist[i]))
+ }
t = 10 días: 518.57 soles
t = 15 días: 494.18 soles
t = 20 días: 470.37 soles
t = 25 días: 404.82 soles
t = 30 días: 364.43 soles
t = 35 días: 310.01 soles
t = 40 días: 263.14 soles
t = 45 días: 217.78 soles
t = 50 días: 157.66 soles
t = 55 días: 108.07 soles
t = 60 días: 45.48 soles
t = 65 días: 10.86 soles
t = 70 días: -11.36 soles
t = 75 días: -73.38 soles
t = 80 días: -145.93 soles
t = 85 días: -181.09 soles
t = 90 días: -240.57 soles
t = 95 días: -278.15 soles
t = 100 días: -342.37 soles
>

> t_optimo_nueva <- t_valores_nueva[which.max(utilidades_nueva_dist)]
>
> cat(sprintf("\n--- RESULTADOS PARTE E ---\n"))

--- RESULTADOS PARTE E ---
> cat(sprintf("PREGUNTA: ¿Cambiaría el tiempo óptimo y el cuantil 0.75 para t=30?\n"))
PREGUNTA: ¿Cambiaría el tiempo óptimo y el cuantil 0.75 para t=30?
> cat(sprintf("RESPUESTA:\n"))
RESPUESTA:
>
> # Comparación de cuantiles 0.75
> diferencia_cuantil <- cuantil_75_nueva - cuantil_75
> cambio_cuantil <- abs(diferencia_cuantil) > 10 # Cambio significativo si > 10 soles
>
> cat(sprintf("Cuantil 0.75 para t=30:\n"))
Cuantil 0.75 para t=30:
> cat(sprintf(" - Poisson: %8.2f soles\n", cuantil_75))
- Poisson: 1763.61 soles
> cat(sprintf(" - Nueva distribución: %8.2f soles\n", cuantil_75_nueva))
- Nueva distribución: 578.88 soles
> cat(sprintf(" - Diferencia: %8.2f soles\n", diferencia_cuantil))
- Diferencia: -1184.74 soles
>
> if(cambio_cuantil) {
+   cat(sprintf(" → SÍ CAMBIA significativamente el cuantil 0.75\n"))
+ } else {
+   cat(sprintf(" → NO cambia significativamente el cuantil 0.75\n"))
+ }
+   → SÍ CAMBIA significativamente el cuantil 0.75
>
> # Comparación de t óptimo
> diferencia_t_optimo <- t_optimo_nueva - t_optimo
> cambio_t_optimo <- abs(diferencia_t_optimo) > 5 # Cambio significativo si > 5 días
>

```

```

> cat(sprintf("\nt óptimo:\n"))

t óptimo:
> cat(sprintf(" - Poisson:          %8d días\n", t_optimo))
- Poisson:          35 días
> cat(sprintf(" - Nueva distribución: %8d días\n", t_optimo_nueva))
- Nueva distribución: 10 días
> cat(sprintf(" - Diferencia:        %+8d días\n", diferencia_t_optimo))
- Diferencia:        -25 días
>
> if(cambio_t_optimo) {
+   cat(sprintf(" → SÍ CAMBIA el tiempo óptimo de contrato\n"))
+ } else {
+   cat(sprintf(" → NO cambia el tiempo óptimo de contrato\n"))
+ }
→ SÍ CAMBIA el tiempo óptimo de contrato
>
> cat(sprintf("\nCONCLUSIÓN PARTE E:\n"))

CONCLUSIÓN PARTE E:
> if(cambio_cuantil || cambio_t_optimo) {
+   cat("La objeción de cambiar el modelo de distribución SÍ tiene impacto en:\n")
+   if(cambio_cuantil) cat("- El cuantil 0.75 de la utilidad\n")
+   if(cambio_t_optimo) cat("- La duración óptima del contrato\n")
+ } else {
+   cat("La objeción de cambiar el modelo NO tiene impacto significativo\n")
+ }
La objeción de cambiar el modelo de distribución SÍ tiene impacto en:
- El cuantil 0.75 de la utilidad
- La duración óptima del contrato
>

> # Comparar características de las distribuciones
> n_comp <- 5000
> cat(sprintf("\nComparación de distribuciones de tiempos de falla (%d muestras):\n", n_comp))

Comparación de distribuciones de tiempos de falla (5000 muestras):
> tiempos_poisson <- replicate(n_comp, simular_tiempo_primera_falla(lambda))
> tiempos_nueva <- replicate(n_comp, generar_tiempo_nueva_distribucion())
>
> cat(sprintf("Distribución Exponencial (Poisson):\n"))
Distribución Exponencial (Poisson):
> cat(sprintf("  Media: %6.2f días, Mediana: %6.2f días, Desv.Std: %6.2f días\n",
+   mean(tiempos_poisson), median(tiempos_poisson), sd(tiempos_poisson)))
Media: 15.00 días, Mediana: 10.32 días, Desv.Std: 15.08 días
>
> cat(sprintf("Nueva distribución:\n"))
Nueva distribución:
> cat(sprintf("  Media: %6.2f días, Mediana: %6.2f días, Desv.Std: %6.2f días\n",
+   mean(tiempos_nueva), median(tiempos_nueva), sd(tiempos_nueva)))
Media: 6.58 días, Mediana: 6.17 días, Desv.Std: 3.49 días
> |

```

Environment

En esta etapa se incorporan funciones y resultados para la nueva distribución de tiempo hasta la primera falla. Objetos como utilidades_30_nueva, cuantil_75_nueva y t_optimo_nueva reflejan una comparación directa con el modelo de Poisson, aumentando la cantidad de información en el Environment. Este incremento en el contenido del entorno es natural, pues se añade un nuevo modelo estadístico que amplía el análisis y permite evaluar la sensibilidad de los resultados frente a cambios en la hipótesis de fallas.

Environment	History	Connections	Tutorial
Import Dataset 124 MiB R Global Environment			
Values			
cambio_cuantil	Named logi TRUE		
cambio_t_optimo	TRUE		
cuantil_75	Named num 1764		
cuantil_75_nueva	Named num 579		
cuantiles_d	Named num [1:5] 16851 19872 22983 25710 27477		
desv_std_d	4460.26281148556		
desviacion_b	990.740647610219		
diferencia_cuantil	Named num -1185		
diferencia_t_optimo	-25		
f_max	0.114368517994761		
fallas_por_maquina	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...		
fallas_totales	58		
i	19L		
idx_optimo	35L		
lambda	0.0666666666666667		
marca	""		
max_d	36725.4622821585		
mediana_d	19872.1526007883		
min_d	4932.67022290296		
n_comp	5000		
n_maquinas_a	12		
n_maquinas_d	20		
n_sim_b	10000		
n_sim_d	10000		
n_sim_e	10000		
prob_sin_falla	0.135335283236613		
promedio_b	1003.02468122554		
promedio_d	19954.9374548353		
promedio_por_maquina	4.83333333333333		
rango_analisis	int [1:7] 32 33 34 35 36 37 38		
t_b	30		
t_d	30		
t_max_densidad	5.30330085889911		

t_optimo	35L
t_optimo_nueva	10
t_values	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...
t_values_nueva	num [1:19] 10 15 20 25 30 35 40 45 50 55 ...
tiempo_a	60
tiempos_nueva	num [1:5000] 1.16 9.6 7.36 17.74 4.04 ...
tiempos_poisson	num [1:5000] 13 22.51 12.94 1.9 7.32 ...
utilidad_maxima	1004.54204820339
utilidad_sin_falla	2700
utilidades_20_maquin...	num [1:10000] 12852 19805 12572 21180 13360 ...
utilidades_30	num [1:10000] 123 395 213 2700 816 ...
utilidades_30_nueva	num [1:10000] 448 -172 407 670 277 ...
utilidades_esperadas	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...
utilidades_nueva_dist	num [1:19] 519 494 470 405 364 ...
valor_esperado_teori...	48
Functions	
calcular_utilidad_es...	function (t)
calcular_utilidad_nu...	function (t)
calcular_utilidad_to...	function (n_maquinas, t)
calcular_utilidad_un...	function (t)
densidad_nueva	function (t)
generar_tiempo_nueva...	function ()
simular_poisson	function (lambda, t)
simular_tiempo_prime...	function (lambda)
utilidad_esperada_nu...	function (t, n_sim = 1000)

Conclusión:

Al considerar una nueva distribución para el tiempo hasta la primera falla, se observó que el t óptimo y el cuantil 0.75 de la utilidad tienen una diferencia notable. Esto evidencia que la elección de la distribución de fallas es importante y puede influir en la estrategia de contratación de la empresa, ya que este nuevo modelo predice fallas mucho más tempranas, lo que reduce bastante el valor que puede tomar el cuantil. Por ejemplo si calculamos el valor para la variable de días pasados hasta la primera falla con la distribución exponencial que se deriva de la Poisson dada en el ejercicio, con esta nueva función de densidad que nos brinda el inciso, se tiene esta diferencia que afecta claramente también al cálculo del cuantil.

Parte f:

Histogramas comparativos de utilidades para 20 máquinas con el modelo de Poisson (izquierda) y la nueva distribución (derecha). Las líneas verticales indican las medias de cada caso. La comparación muestra cómo la variabilidad y el promedio de utilidades se ven afectados al cambiar la suposición del modelo de fallas.

```
Console Terminal Background Jobs
R 4.4.3 · ~/
> # =====
> # PARTE F: Comparación de resultados con 20 máquinas
> # =====
> cat("\n=== PARTE F ===\n")

=== PARTE F ===
> cat("Simulación de 20 máquinas con nueva distribución\n")
Simulación de 20 máquinas con nueva distribución
> cat("Comparación con resultados de distribución Poisson\n\n")
Comparación con resultados de distribución Poisson

>
> # Función para calcular utilidad total con la nueva distribución
> calcular_utilidad_total_nueva <- function(n_maquinas, t) {
+   utilidad_total <- 0
+   for(i in 1:n_maquinas) {
+     utilidad_total <- utilidad_total + calcular_utilidad_nueva_dist(t)
+   }
+   return(utilidad_total)
+ }
>
> # Simulación con nueva distribución (mismo número de simulaciones que parte D)
> n_sim_f <- 10000
> cat(sprintf("Realizando %d simulaciones con nueva distribución...\n", n_sim_f))
Realizando 10000 simulaciones con nueva distribución...
>
> utilidades_20_nueva <- replicate(n_sim_f, calcular_utilidad_total_nueva(20, 30))
>
> # Estadísticas descriptivas
> promedio_f <- mean(utilidades_20_nueva)
> desv_std_f <- sd(utilidades_20_nueva)
> mediana_f <- median(utilidades_20_nueva)
> min_f <- min(utilidades_20_nueva)
> max_f <- max(utilidades_20_nueva)
>
```

```

> cat(sprintf("\n--- RESULTADOS PARTE F ---\n"))

--- RESULTADOS PARTE F ---
> cat(sprintf("Nueva distribución - 20 máquinas, t=30 días:\n"))
Nueva distribución - 20 máquinas, t=30 días:
> cat(sprintf("Promedio de utilidades: %10.2f soles\n", promedio_f))
Promedio de utilidades: 7305.52 soles
> cat(sprintf("Desviación estándar: %10.2f soles\n", desv_std_f))
Desviación estándar: 1565.40 soles
> cat(sprintf("Mediana: %10.2f soles\n", mediana_f))
Mediana: 7246.87 soles
> cat(sprintf("Mínimo: %10.2f soles\n", min_f))
Mínimo: 2038.78 soles
> cat(sprintf("Máximo: %10.2f soles\n", max_f))
Máximo: 13065.78 soles
>
> # Comparación detallada entre ambas distribuciones
> diferencia_promedio <- promedio_f - promedio_d
> diferencia_std <- desv_std_f - desv_std_d
> diferencia_porcentual_promedio <- 100 * diferencia_promedio / promedio_d
> diferencia_porcentual_std <- 100 * diferencia_std / desv_std_d
>
> cat(sprintf("\n--- COMPARACIÓN ENTRE DISTRIBUCIONES ---\n"))

--- COMPARACIÓN ENTRE DISTRIBUCIONES ---
> cat(sprintf("Métrica Poisson Poisson Nueva Dist. Diferencia %%Cambio\n"))
Métrica Poisson Poisson Nueva Dist. Diferencia %%Cambio
> cat(sprintf("%-20s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Promedio", promedio_d, promedio_f, diferencia_promedio, diferencia_porcentual_promedio))
Promedio 19954.94 7305.52 -12649.41 -63.4%
> cat(sprintf("%-20s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Desv. Estándar", desv_std_d, desv_std_f, diferencia_std, diferencia_porcentual_std))
Desv. Estándar 4460.26 1565.40 -2894.86 -64.9%
> cat(sprintf("%-20s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Mediana", mediana_d, mediana_f, mediana_f - mediana_d,
+ 100 * (mediana_f - mediana_d) / mediana_d))
Mediana 19872.15 7246.87 -12625.28 -63.5%
>

> # Análisis estadístico adicional
> # Test de diferencia de medias (aproximado usando CLT)
> error_estandar_dif <- sqrt((desv_std_d^2 + desv_std_f^2) / n_sim_d)
> estadistico_t <- diferencia_promedio / error_estandar_dif
> p_valor_aprox <- 2 * (1 - pnorm(abs(estadistico_t)))
>
> cat(sprintf("\nAnálisis de significancia estadística:\n"))

Análisis de significancia estadística:
> cat(sprintf("Error estándar de la diferencia: %.2f\n", error_estandar_dif))
Error estándar de la diferencia: 47.27
> cat(sprintf("Estadístico t aproximado: %.3f\n", estadistico_t))
Estadístico t aproximado: -267.600
> cat(sprintf("p-valor aproximado: %.6f\n", p_valor_aprox))
p-valor aproximado: 0.000000
>
> if(p_valor_aprox < 0.001) {
+ cat("La diferencia es ALTAMENTE SIGNIFICATIVA (p < 0.001)\n")
+ } else if(p_valor_aprox < 0.01) {
+ cat("La diferencia es MUY SIGNIFICATIVA (p < 0.01)\n")
+ } else if(p_valor_aprox < 0.05) {
+ cat("La diferencia es SIGNIFICATIVA (p < 0.05)\n")
+ } else {
+ cat("La diferencia NO es estadísticamente significativa (p ≥ 0.05)\n")
+ }
La diferencia es ALTAMENTE SIGNIFICATIVA (p < 0.001)
>


```

```

> # Gráfico comparativo
> par(mfrow=c(1,2))
>
> # Histograma Poisson
> hist(utilidades_20_maquinas, breaks=50,
+      col=rgb(0,0,1,0.5), border="blue",
+      main="Distribución Poisson\n(20 máquinas, 30 días)",
+      xlab="Utilidad (soles)", ylab="Frecuencia",
+      xlim=c(min(c(utilidades_20_maquinas, utilidades_20_nueva)),
+             max(c(utilidades_20_maquinas, utilidades_20_nueva))))
> abline(v=promedio_d, col="blue", lwd=3)
>
> # Histograma Nueva distribución
> hist(utilidades_20_nueva, breaks=50,
+      col=rgb(1,0,0,0.5), border="red",
+      main="Nueva Distribución\n(20 máquinas, 30 días)",
+      xlab="Utilidad (soles)", ylab="Frecuencia",
+      xlim=c(min(c(utilidades_20_maquinas, utilidades_20_nueva)),
+             max(c(utilidades_20_maquinas, utilidades_20_nueva))))
> abline(v=promedio_f, col="red", lwd=3)
>
> par(mfrow=c(1,1))
>

```

Histogramas comparativos de utilidades para el alquiler de 20 máquinas durante 30 días, usando el modelo de Poisson (izquierda) y la nueva distribución de tiempos de falla (derecha). Cada histograma incluye la línea de la media respectiva, lo que permite visualizar cómo cambia el promedio y la dispersión de las utilidades entre ambos modelos. La comparación evidencia si la nueva distribución genera un incremento o reducción en la rentabilidad esperada y en la variabilidad de los resultados.



Environment

El Environment alcanza su máxima extensión al almacenar los resultados de 10,000 simulaciones con la nueva distribución (utilidades_20_nueva) junto con comparaciones directas frente a los datos de Poisson, métricas de diferencia absoluta y relativa, y resultados del análisis de significancia estadística. La riqueza de objetos en esta etapa es muestra de la culminación de la práctica, integrando simulaciones complejas, estadísticos comparativos y pruebas de hipótesis para obtener conclusiones más sólidas.

Environment	History	Connections	Tutorial
R 126 MiB			
Global Environment			
Values			
cambio_cuantil	Named logi	TRUE	
cambio_t_optimo		TRUE	
cuantil_75	Named num	1764	
cuantil_75_nueva	Named num	579	
cuantiles_d	Named num	[1:5] 16851 19872 22983 25710 27477	
desv_std_d		4460.26281148556	
desv_std_f		1565.4006885164	
desviacion_b		990.740647610219	
diferencia_cuantil	Named num	-1185	
diferencia_porcentua...		-63.3898965295997	
diferencia_porcentua...		-64.9033979682687	
diferencia_promedio		-12649.4142051665	
diferencia_std		-2894.86212296916	
diferencia_t_optimo		-25	
error_estandar_dif		47.2698885794421	
estadistico_t		-267.599831209836	
f_max		0.114368517994761	
fallas_por_maquina	num [1:12]	5 8 2 10 5 4 3 2 3 4 ...	
fallas_totales		58	
i		19L	
idx_optimo		35L	
lambda		0.0666666666666667	
marca		""	
max_d		36725.4622821585	
max_f		13065.7824266236	
mediana_d		19872.1526007883	
mediana_f		7246.87278596684	
min_d		4932.67022290296	
min_f		2038.77859842032	
n_comp		5000	
n_maquinas_a		12	
n_maquinas_d		20	
n_sim_b		10000	
n_sim_d		10000	

n_sim_e	10000
n_sim_f	10000
p_valor_aprox	0
prob_sin_falla	0.135335283236613
promedio_b	1003.02468122554
promedio_d	19954.9374548353
promedio_f	7305.52324966888
promedio_por_maquina	4.83333333333333
rango_analisis	int [1:7] 32 33 34 35 36 37 38
t_b	30
t_d	30
t_max_densidad	5.30330085889911
t_optimo	35L
t_optimo_nueva	10
t_values	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...
t_values_nueva	num [1:19] 10 15 20 25 30 35 40 45 50 55 ...
tiempo_a	60
tiempos_nueva	num [1:5000] 1.16 9.6 7.36 17.74 4.04 ...
tiempos_poisson	num [1:5000] 13 22.51 12.94 1.9 7.32 ...
utilidad_maxima	1004.54204820339
utilidad_sin_falla	2700
utilidades_20_maquin...	num [1:10000] 12852 19805 12572 21180 13360 ...
utilidades_20_nueva	num [1:10000] 7393 5708 6121 6470 6357 ...
utilidades_30	num [1:10000] 123 395 213 2700 816 ...
utilidades_30_nueva	num [1:10000] 448 -172 407 670 277 ...
utilidades_esperadas	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...
utilidades_nueva_dist	num [1:19] 519 494 470 405 364 ...
valor_esperado_teori...	48
Functions	
calcular_utilidad_es...	function (t)
calcular_utilidad_nu...	function (t)
calcular_utilidad_to...	function (n_maquinas, t)
calcular_utilidad_to...	function (n_maquinas, t)
calcular_utilidad_un...	function (t)
densidad_nueva	function (t)
generar_tiempo_nueva...	function ()
simular_poisson	function (lambda, t)
simular_tiempo_prime...	function (lambda)
utilidad_esperada_nu...	function (t, n_sim = 1000)

Conclusión:

La comparación entre las utilidades simuladas con el modelo de Poisson y con la nueva distribución mostró diferencias estadísticamente significativas en la media y la variabilidad. Esto sugiere que un mejor modelado de la distribución de fallas podría impactar de forma importante en la planificación financiera de la empresa.