

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ
FACULTAD DE CIENCIAS E INGENIERÍA



Parte dirigida

Curso : Probabilidad y Estadística
Horario : 0681
Profesor : Valdivieso
Práctica : 02
Nombres y códigos :
- 20220286 - EISEN JACK MATEO MENDOZA

SEMESTRE 2025-2

Solución a los incisos, empleando para ello el lenguaje R:

Inciso A:

Planteamos la solución de la siguiente manera y justificando la decisión de las elecciones en los parámetros del lenguaje R:

El proceso de Poisson con tasa " λ " por unidad de tiempo se caracteriza por tener tiempos entre eventos independientes y distribuidos exponencialmente con parámetro λ . Para una máquina, el número de fallas en un intervalo de tiempo " t " sigue una distribución de Poisson con media " λt ". Sin embargo, al no permitirse el uso de rpois, simulamos el proceso generando los tiempos entre fallas como variables aleatorias exponenciales. Para cada máquina, se generan tiempos entre fallas hasta que la suma de estos tiempos exceda el tiempo total $t=60$ días.

El número de fallas por máquina es el conteo de eventos antes de que esto ocurra. La cantidad total de fallas para las 12 máquinas es la suma de las fallas individuales.

Se considera un periodo de mes por 30 días, y en 60 días para 2 meses, pues así se obtiene un modelado más preciso, ya que el modelo de Poisson trabaja mejor en intervalos de tiempo pequeños, como en este caso. Se puede usar un periodo de λ por mes, sin embargo, optamos por elegir un periodo de días, tanto por practicidad como para trabajar mejor más adelante. Cabe mencionar que los resultados obtenidos de modelar en ambos periodos serían similares y equivalentes.

Los parámetros son los siguientes:

- Tasa de fallas $\lambda = 2/30$ fallas por día.
- Tiempo total $t = 60$ días.
- Número de máquinas $n = 12$

Validación del modelo:

- Valor esperado teórico: $E[\text{fallas}] = \lambda \times t \times n = 0.0667 \times 60 \times 12 = 48$ fallas
- Resultado simulado: 58 fallas (diferencia de +10 fallas)
- Consistencia: La diferencia representa aproximadamente el 21% del valor esperado, lo que es aceptable dada la variabilidad inherente del proceso de Poisson

```

> #-----INCISO A - PC2 - 25_2 -----
> #SIMULACION USANDO EL MODELO DE POISSON
> # Inciso a: Simulación de fallas para 12 máquinas por 60 días (2 meses)
> lambda_dia <- 2/30 # Tasa de fallas por día (2 fallas/mes ÷ 30 días)
> tiempo_total_dias <- 60 # 2 meses = 60 días
> num_maquinas <- 12
>
> # Función para simular proceso de Poisson por días (método de transformación inversa)
> simular_fallas_maquina_dias <- function(lambda, tiempo_total) {
+   tiempo_actual <- 0
+   num_fallas <- 0
+   while (TRUE) {
+     # Generar tiempo entre fallas usando transformación inversa
+     tiempo_entre <- -log(runif(1)) / lambda
+     tiempo_actual <- tiempo_actual + tiempo_entre
+
+     # Contar solo si la falla ocurre ANTES del tiempo total (no inclusive)
+     if (tiempo_actual < tiempo_total) {
+       num_fallas <- num_fallas + 1
+     } else {
+       break
+     }
+   }
+   return(num_fallas)
+ }
>
> # Fijar semilla para reproducibilidad
> set.seed(123)
>
> # Simular fallas para cada máquina y calcular el total
> total_fallas <- 0
> fallas_individuales <- numeric(num_maquinas)
>

```

```

> for (i in 1:num_maquinas) {
+   fallas_maquina <- simular_fallas_maquina_dias(lambda_dia, tiempo_total_dias)
+   fallas_individuales[i] <- fallas_maquina
+   total_fallas <- total_fallas + fallas_maquina
+ }
>
> # Resultados
> cat("=== PARTE A - SIMULACIÓN POR DÍAS ===\n")
=== PARTE A - SIMULACIÓN POR DÍAS ===
> cat("Parámetros:\n")
Parámetros:
> cat("- Tasa de fallas:", lambda_dia, "fallas por día\n")
- Tasa de fallas: 0.06666667 fallas por día
> cat("- Tiempo total:", tiempo_total_dias, "días\n")
- Tiempo total: 60 días
> cat("- Número de máquinas:", num_maquinas, "\n\n")
- Número de máquinas: 12
>
> cat("Fallas por máquina:\n")
Fallas por máquina:
> for (i in 1:num_maquinas) {
+   cat(sprintf("Máquina %2d: %d fallas\n", i, fallas_individuales[i]))
+ }

```

```

Máquina 1: 5 fallas
Máquina 2: 8 fallas
Máquina 3: 2 fallas
Máquina 4: 10 fallas
Máquina 5: 5 fallas
Máquina 6: 4 fallas
Máquina 7: 3 fallas
Máquina 8: 2 fallas
Máquina 9: 3 fallas
Máquina 10: 4 fallas
Máquina 11: 5 fallas
Máquina 12: 7 fallas
>
> cat(sprintf("\nTotal de fallas simuladas: %d\n", total_fallas))

Total de fallas simuladas: 58
> cat(sprintf("Promedio por máquina: %.2f fallas\n", mean(fallas_individuales)))
Promedio por máquina: 4.83 fallas
>
> # Verificación teórica
> valor_esperado_teorico <- num_maquinas * lambda_dia * tiempo_total_dias
> cat(sprintf("Valor esperado teórico: %.2f fallas\n", valor_esperado_teorico))
Valor esperado teórico: 48.00 fallas
> cat(sprintf("Diferencia: %.2f fallas\n", total_fallas - valor_esperado_teorico))
Diferencia: 10.00 fallas
> |

```

Values	
fallas_individu...	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...
fallas_maquina	7
i	12L
lambda	2
lambda_dia	0.06666666666666667
num_maquinas	12
resultado	43
tiempo_total	2
tiempo_total_di...	60
total_fallas	58
valor_esperado_...	48
Functions	
simular_fallas_...	function (lambda, tiempo_total, num_maqui... 
simular_fallas_...	function (lambda, tiempo_total) 
simular_fallas_...	function (lambda, tiempo_total) 

Interpretación:

Al ejecutar el modelo, solo contamos las fallas que ocurren estrictamente antes del tiempo total. El valor teórico (48 fallas) es un promedio esperado, es decir, en cualquier realización particular del proceso, el resultado varía aleatoriamente, además, si seguimos la distribución de Poisson, se tiene una varianza igual a la media ($\sigma^2 = \mu$).

Asimismo, empleando el cálculo de la variabilidad esperada obtenemos lo siguiente:

```
media_teorica <- 48
desviacion_teorica <- sqrt(media_teorica) # Para Poisson:  $\sigma = \sqrt{\mu}$ 
desviacion_teorica #  $\approx 6.93$  fallas
```

Rango de variación normal: $48 \pm 2 \times 6.93 = [34.14, 61.86]$ fallas

El resultado obtenido (58) se encuentra en el rango esperado.

```
# Test de cuántas desviaciones estándar nos alejamos de la media
z_score <- (58 - 48) / sqrt(48)
z_score #  $\approx 1.44$ 
```

Una diferencia de 1.44 desviaciones estándar es moderada y completamente normal en procesos aleatorios.

Conclusión:

La cantidad de fallas que presentarán las 12 máquinas en dos meses (60 días) es de 48. Hay aproximadamente 7.4% de probabilidad de observar 58 o más fallas por puro azar cuando el valor esperado es 48. La diferencia de +10 fallas es estadísticamente normal y esperable porque, refleja la variabilidad inherente de los procesos de Poisson y está dentro de los límites de fluctuación aleatoria ($\approx 1.44 \sigma$). La simulación está capturando correctamente el comportamiento aleatorio del proceso de fallas, y la diferencia con el valor teórico demuestra por qué en la práctica debemos considerar intervalos de confianza, no solo valores puntuales.

Inciso b:

Obtenemos los siguientes datos para hallar el cuantil de 0.75 de la utilidad para $t = 30$ días, de una salida de la simulación de 10,000 contratos de 30 días para una máquina, en la que se muestra el cuantil 0.75 de la utilidad, la media, la desviación estándar y los valores extremos:

- Precio de venta: 150 soles/día
- Costo de compra: 60 soles/día
- Costo de reemplazo: 100 soles/día (si falla)

```

> #=====
> #                                INCISO B
> #=====
> # --- CONFIGURACIÓN INICIAL ---
> set.seed(123) # Para reproducibilidad de resultados
>
> # Parámetros del problema
> lambda <- 2/30 # Tasa de fallas por día (2 fallas por mes de 30 días)
>
> cat("=== PARTE B - CÁLCULO DEL CUANTIL 0.75 ===\n")
=== PARTE B - CÁLCULO DEL CUANTIL 0.75 ===
> cat("Parámetros del problema:\n")
Parámetros del problema:
> cat(sprintf("- Tasa de fallas: %.4f fallas por día\n", lambda))
- Tasa de fallas: 0.0667 fallas por día
> cat(sprintf("- Equivalente a: %.2f fallas por mes\n\n", lambda * 30))
- Equivalente a: 2.00 fallas por mes

>
> cat("Modelo de negocio y cálculo de utilidades\n")
Modelo de negocio y cálculo de utilidades
> cat("Parámetros económicos:\n")
Parámetros económicos:
> cat("- Precio de alquiler a minera: 150 soles/día\n")
- Precio de alquiler a minera: 150 soles/día
> cat("- Costo de renta al fabricante: 60 soles/día\n")
- Costo de renta al fabricante: 60 soles/día
> cat("- Costo de máquina de reemplazo: 100 soles/día\n\n")
- Costo de máquina de reemplazo: 100 soles/día

<
> # --- FUNCIONES ---
> # Función para simular tiempo hasta primera falla (distribución exponencial)
> simular_tiempo_primera_falla <- function(lambda) {
+   return(-log(runif(1)) / lambda)
+ }
>
> # Función para calcular utilidad de UNA máquina
> calcular_utilidad_una_maquina <- function(t) {
+   # Modelo de ingresos y costos
+   ingresos <- 150 * t # 150 soles por día durante t días
+   costo_base <- 60 * t # 60t soles pagados al fabricante
+
+   # Simular tiempo hasta primera falla de la máquina original
+   tiempo_falla_original <- simular_tiempo_primera_falla(lambda)
+
+   if (tiempo_falla_original <= t) {
+     # La máquina original falla dentro del período de contrato
+     dias_restantes <- t - tiempo_falla_original
+
+     # Costo adicional: 100 soles por día por la máquina de reemplazo
+     # Se paga por todos los días restantes del contrato
+     costo_adicional <- 100 * dias_restantes
+     utilidad <- ingresos - costo_base - costo_adicional
+   } else {
+     # No hay falla de la máquina original durante el contrato
+     utilidad <- ingresos - costo_base # = 90*t
+   }
+
+   return(utilidad)
+ }
<

```

```

> # --- SIMULACIÓN PRINCIPAL ---
> t_b <- 30
> n_sim_b <- 10000
>
> cat(sprintf("Simulando %d utilidades para t=%d días...\n", n_sim_b, t_b))
Simulando 10000 utilidades para t=30 días...
> utilidades_30 <- replicate(n_sim_b, calcular_utilidad_una_maquina(t_b))
>
> # --- CÁLCULO DE ESTADÍSTICAS ---
> cuantil_75 <- quantile(utilidades_30, 0.75)
> promedio_b <- mean(utilidades_30)
> desviacion_b <- sd(utilidades_30)
>
> cat(sprintf("\n--- RESULTADOS PARTE B ---\n"))

--- RESULTADOS PARTE B ---
> cat(sprintf("Para t = %d días (una máquina):\n", t_b))
Para t = 30 días (una máquina):
> cat(sprintf("Cuantil 0.75 de la utilidad: %.2f soles\n", cuantil_75))
Cuantil 0.75 de la utilidad: 1762.19 soles
> cat(sprintf("Utilidad promedio: %.2f soles\n", promedio_b))
Utilidad promedio: 1001.70 soles
> cat(sprintf("Desviación estándar: %.2f soles\n", desviacion_b))
Desviación estándar: 990.46 soles
> cat(sprintf("Utilidad mínima: %.2f soles\n", min(utilidades_30)))
Utilidad mínima: -299.91 soles
> cat(sprintf("Utilidad máxima: %.2f soles\n", max(utilidades_30)))
Utilidad máxima: 2700.00 soles
>
> # --- ANÁLISIS TEÓRICO ADICIONAL ---
> prob_sin_falla <- exp(-lambda * t_b)
> utilidad_sin_falla <- 90 * t_b

> cat(sprintf("\n--- ANÁLISIS TEÓRICO ---\n"))

--- ANÁLISIS TEÓRICO ---
> cat(sprintf("P(sin falla en %d días): %.3f\n", t_b, prob_sin_falla))
P(sin falla en 30 días): 0.135
> cat(sprintf("Utilidad si no hay falla: %.0f soles\n", utilidad_sin_falla))
Utilidad si no hay falla: 2700 soles
>
> # --- ANÁLISIS DE DISTRIBUCIÓN ---
> cat(sprintf("\n--- DISTRIBUCIÓN DE RESULTADOS ---\n"))

--- DISTRIBUCIÓN DE RESULTADOS ---
> cat(sprintf("Porcentaje de contratos con utilidad máxima: %.1f%%\n",
+             sum(utilidades_30 == utilidad_sin_falla) / n_sim_b * 100))
Porcentaje de contratos con utilidad máxima: 13.2%
> cat(sprintf("Porcentaje de contratos con pérdida: %.1f%%\n",
+             sum(utilidades_30 < 0) / n_sim_b * 100))
Porcentaje de contratos con pérdida: 17.6%
>
> # --- INTERVALOS DE UTILIDAD ---
> intervalos <- cut(utilidades_30,
+                   breaks = c(-Inf, 0, 500, 1000, 1500, 2000, 2500, Inf))
> tabla_intervalos <- table(intervalos)
> cat(sprintf("\nDistribución por intervalos de utilidad:\n"))

Distribución por intervalos de utilidad:
> print(prop.table(tabla_intervalos) * 100)
intervalos
      (-Inf,0]      (0,500]      (500,1e+03] (1e+03,1.5e+03]
      17.64      23.13      17.11      11.85
(1.5e+03,2e+03] (2e+03,2.5e+03] (2.5e+03, Inf]
      8.95      6.01      15.31

```

Values	
cuantil_75	Named num 1762
desviacion_b	990.457704950433
fallas_individual...	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...
fallas_maquina	7
i	12L
intervalos	Factor w/ 7 levels "(-Inf,0]","(0,500]",...: 5 2 ...
lambda	0.0666666666666667
lambda_dia	0.0666666666666667
n_sim_b	10000
num_maquinas	12
prob_sin_falla	0.135335283236613
promedio_b	1001.70478567954
t_b	30
tabla_intervalos	'table' int [1:7(1d)] 1764 2313 1711 1185 895 60...
tiempo_total_dias	60
total_fallas	58
utilidad_sin_falla	2700
utilidades_30	num [1:10000] 1569.4 56.8 1041.1 -113.4 -207.9
valor_esperado_te...	48
Functions	
calcular_utilidad...	function (t) 
simular_fallas_ma...	function (lambda, tiempo_total) 
simular_tiempo_pr...	function (lambda) 

Interpretación:

1762.19 soles representa el valor que supera el 75% de las utilidades simuladas. Esto significa que en 3 de cada 4 contratos, la empresa obtendrá al menos esta utilidad, es decir, es un umbral de seguridad para la planificación financiera. Con la siguiente distribución de resultados:

- Mejor escenario: 2700 soles (sin fallas, probabilidad $\approx 13.5\%$)
- Peor escenario: -299.91 soles (falla muy temprana)
- Variabilidad alta: Desviación estándar de 990.74 soles indica riesgo significativo.

La probabilidad teórica de no tener fallas en 30 días es:

$$P(\text{sin falla}) = \exp(-\lambda t) = \exp(-(2/30)*30) = \exp(-2) \approx 0.135$$

Nuestra simulación muestra 13.4%, lo que valida la correcta implementación.

Asimismo, se sigue el siguiente análisis económico;

- Margen bruto sin fallas: 90 soles/día $\times$ 30 días = 2700 soles

- Costo de falla: 100 soles/día por días restantes después de la falla
- El cuantil 0.75 (1763.61) está cerca del punto medio entre el peor y mejor caso, indicando que en la mayoría de escenarios se mantienen utilidades positivas sustanciales.

Y a partir del análisis presentado se puede considerar que se pueden esperar con 75% de confianza al menos 1763.61 soles por contrato en relación a la planificación conservadora, además, para la gestión de riesgos, la alta desviación estándar sugiere necesidad de reservas para cubrir contratos con pérdidas. Por último, la estrategia de precios que sigue el modelo actual, permite evaluar diferentes estructuras de costos y precios

Conclusión:

El cuantil 0.75 de 1763.61 soles proporciona una métrica robusta para la toma de decisiones, indicando que la empresa puede esperar con alta confianza obtener al menos esta utilidad en contratos individuales de 30 días.

Inciso C:

Gráfico de la utilidad esperada en función de la duración del contrato (t). La curva muestra un máximo claro alrededor de $t = [\text{valor encontrado}]$ días, que es resaltado con una línea vertical y un punto rojo. Esta visualización confirma el valor óptimo de t que maximiza la utilidad esperada de la empresa.

```
> #=====
> #INCISO C Valor óptimo de t que maximiza utilidad esperada
> #=====
> cat("Búsqueda del valor óptimo de t (días enteros)\n\n")
Búsqueda del valor óptimo de t (días enteros)

>
> # Función para calcular utilidad esperada teóricamente (más eficiente y precisa)
> calcular_utilidad_esperada_teorica <- function(t) {
+   # p(no_falla en [0,t]) = exp(-λt)
+   prob_no_falla <- exp(-lambda * t)
+
+   # utilidad si no hay falla durante el contrato
+   utilidad_sin_falla <- 150 * t - 60 * t # = 90*t
+
+   # Si hay falla, el tiempo esperado de falla dado que falla en [0,t] es:
+   #  $E[T | T \leq t] = (1 - (1 + \lambda t)\exp(-\lambda t)) / (\lambda(1 - \exp(-\lambda t)))$ 
+   if(lambda * t < 1e-10) {
+     # para λt muy pequeño, usar aproximación de Taylor
+     tiempo_falla_esperado <- t / 2
+   } else {
+     numerador <- 1 - (1 + lambda * t) * exp(-lambda * t)
+     denominador <- lambda * (1 - exp(-lambda * t))
+     tiempo_falla_esperado <- numerador / denominador
+   }
+
+   # Utilidad esperada si hay falla
+   dias_restantes_esperados <- t - tiempo_falla_esperado
+   utilidad_con_falla <- 150 * t - 60 * t - 100 * dias_restantes_esperados
+
+   # Utilidad esperada total usando ley de expectativa total
+   utilidad_esperada <- prob_no_falla * utilidad_sin_falla + (1 - prob_no_falla)
+   * utilidad_con_falla
+   return(utilidad_esperada)
+ }
```

```

> # Búsqueda del t óptimo (días enteros)
> t_values <- 1:200 # Rango amplio de búsqueda
> cat("Calculando utilidad esperada teórica...\n")
Calculando utilidad esperada teórica...
> utilidades_esperadas <- sapply(t_values, calcular_utilidad_esperada_teorica)
>
> # Encontrar el óptimo
> t_optimo <- t_values[which.max(utilidades_esperadas)]
> utilidad_maxima <- max(utilidades_esperadas)
>
> cat(sprintf("\n--- RESULTADOS PARTE C ---\n"))


--- RESULTADOS PARTE C ---
> cat(sprintf("Valor óptimo de t: %d días\n", t_optimo))
Valor óptimo de t: 35 días
> cat(sprintf("Utilidad esperada máxima: %.2f soles\n", utilidad_maxima))
Utilidad esperada máxima: 1004.54 soles
>
> # Mostrar valores alrededor del óptimo para verificación
> idx_optimo <- which.max(utilidades_esperadas)
> rango_analisis <- max(1, idx_optimo-3):min(length(t_values), idx_optimo+3)
> cat(sprintf("\nUtilidades esperadas cerca del óptimo:\n"))

Utilidades esperadas cerca del óptimo:
> for(i in rango_analisis) {
+   marca <- if(i == idx_optimo) " <- ÓPTIMO" else ""
+   cat(sprintf("t = %3d días: %8.2f soles%s\n", t_values[i], utilidades_esperadas
[i], marca))
+ }
t = 32 días: 1002.34 soles
t = 33 días: 1003.80 soles
t = 34 días: 1004.51 soles
t = 35 días: 1004.54 soles <- ÓPTIMO
t = 36 días: 1003.92 soles
t = 37 días: 1002.70 soles
t = 38 días: 1000.91 soles

> # Crear gráfico de utilidad esperada vs t
> plot(t_values[1:100], utilidades_esperadas[1:100],
+      type = "l", col = "blue", lwd = 2,
+      xlab = "Días de contrato (t)",
+      ylab = "Utilidad esperada (soles)",
+      main = "Utilidad Esperada vs Duración del Contrato")
> abline(v = t_optimo, col = "red", lty = 2, lwd = 2)
> points(t_optimo, utilidad_maxima, col = "red", pch = 19, cex = 1.5)
> text(t_optimo + 8, utilidad_maxima - 30,
+      paste("t* =", t_optimo, "días\nU* =", round(utilidad_maxima, 1), "soles"),
+      col = "red", cex = 0.9)
> grid(col = "gray", lty = 3)

```

Utilidad Esperada vs Duración del Contrato



Interpretación:

Se empleó un enfoque teórico en lugar de simulación para tener una mayor precisión, además se tuvo en cuenta la ley expectativa total para calcular la utilidad esperada, obteniendo así una optimización exhaustiva sobre $t = 1$ a 200 días.

Probabilidad de no falla: $P(T > t) = \exp(-\lambda t)$

Utilidad sin falla: $90t$

Tiempo esperado de falla dado que falla: $E[T|T \leq t] = (1 - (1 + \lambda t)e^{(-\lambda t)}) / (\lambda(1 - e^{(-\lambda t)}))$

Utilidad esperada total: $E[U] = P(\text{no falla}) \times 90t + P(\text{falla}) \times [90t - 100 \times (t - E[T|T \leq t])]$

De igual manera, desde una interpretación económica, se tiene que $t = 35$ días representa el punto óptimo que balancea tanto ingresos crecientes con la duración del contrato, como costos esperados por fallas que también aumentan con t .

Para el análisis de sensibilidad existen pequeñas variaciones alrededor de 35 días, los cuales tienen impacto mínimo, por la siguiente rentabilidad comparativa:

- Contrato óptimo (35 días): 1004.54 soles

- Contrato de 30 días: ≈ 1003 soles (0.15% menos)
- Contrato de 40 días: ≈ 1000 soles (0.45% menos)

Por último, las siguientes probabilidades en el óptimo, muestran la cercanía de datos y el rango de fallo aceptado.

```
prob_falla_35 <- 1 - exp(-lambda * 35) #  $\approx 90.3\%$ 
```

```
prob_sin_falla_35 <- exp(-lambda * 35) #  $\approx 9.7\%$ 
```

Environment	History	Connections	Tutorial
Import Dataset	125 MiB		
R	Global Environment		
Valores			
cuantil_75	Named num 1762		
cuantiles_d	Named num [1:5] 16901 19843 22962 25736 27451		
desv_std_d	4450.26320327606		
desviacion_b	990.457704950433		
fallas_individuales	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...		
fallas_maquina	7		
i	38L		
idx_optimo	35L		
intervalos	Factor w/ 7 levels "(-Inf,0]", "(0,500]", ...: 5 2 4 1 1 7 3 1 ...		
lambda	0.0666666666666667		
lambda_dia	0.0666666666666667		
marca	""		
max_d	38289.6218929656		
mediana_d	19842.6390497876		
min_d	4677.71512449395		
n_maquinas_d	20		
n_sim_b	10000		
n_sim_d	10000		
num_maquinas	12		
prob_sin_falla	0.135335283236613		
promedio_b	1001.70478567954		
promedio_d	19954.9348737068		
rango_analisis	int [1:7] 32 33 34 35 36 37 38		
t_b	30		
t_d	30		
t_optimo	35L		
t_values	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...		

tabla_intervalos	'table' int [1:7(1d)] 1764 2313 1711 1185 895 601 1531
tiempo_total_dias	60
total_fallas	58
utilidad_esperada_te...	1003.02
utilidad_esperada_te...	20060.4
utilidad_maxima	1004.54204820339
utilidad_sin_falla	2700
utilidades_20_maquin...	num [1:10000] 18386 21416 29901 17165 17380 ...
utilidades_30	num [1:10000] 1569.4 56.8 1041.1 -113.4 -207.9 ...
utilidades_esperadas	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...
valor_esperado_teori...	48
Functions	
calcular_utilidad_es...	function (t)
calcular_utilidad_to...	function (n_maquinas, t)
calcular_utilidad_un...	function (t)
simular_fallas_maqui...	function (lambda, tiempo_total)
simular_tiempo_prime...	function (lambda)

Conclusión:

El valor óptimo de $t = 35$ días maximiza la utilidad esperada en 1004.54 soles, representando el mejor balance entre maximizar ingresos y gestionar el riesgo de fallas.

Inciso D:

Histograma de las ganancias simuladas para el alquiler de 20 máquinas durante 30 días en 10,000 experimentos. La línea roja representa la media y la línea naranja la mediana. Se observa que la distribución es casi simétrica, lo que confirma que la media y la mediana están cerca una de la otra..

```

> #=====
> #INCISO D Simulación para 20 máquinas con distribución Poisson
> #=====
>
> cat("Simulación de utilidades para múltiples máquinas\n")
Simulación de utilidades para múltiples máquinas
> cat("20 máquinas, t=30 días, 10,000 simulaciones\n\n")
20 máquinas, t=30 días, 10,000 simulaciones

>
> # Función para calcular utilidad total de múltiples máquinas
> calcular_utilidad_total <- function(n_maquinas, t) {
+   utilidad_total <- 0
+   for(i in 1:n_maquinas) {
+     utilidad_total <- utilidad_total + calcular_utilidad_una_maquina(t)
+   }
+   return(utilidad_total)
+ }
>
> # Parámetros para parte D
> n_maquinas_d <- 20
> t_d <- 30
> n_sim_d <- 10000
>
> cat(sprintf("Realizando %d simulaciones...\n", n_sim_d))
Realizando 10000 simulaciones...
> cat("Cada simulación representa el alquiler simultáneo de 20 máquinas\n")
Cada simulación representa el alquiler simultáneo de 20 máquinas
>
> # Realizar simulaciones
> utilidades_20_maquinas <- replicate(n_sim_d, calcular_utilidad_total(n_maquinas_d, t_d))

> # Estadísticas descriptivas
> promedio_d <- mean(utilidades_20_maquinas)
> desv_std_d <- sd(utilidades_20_maquinas)
> mediana_d <- median(utilidades_20_maquinas)
> min_d <- min(utilidades_20_maquinas)
> max_d <- max(utilidades_20_maquinas)
>
> cat(sprintf("\n--- RESULTADOS PARTE D ---\n"))

--- RESULTADOS PARTE D ---
> cat(sprintf("Distribución Poisson - 20 máquinas, t=30 días:\n"))
Distribución Poisson - 20 máquinas, t=30 días:
> cat(sprintf("Promedio de utilidades: %10.2f soles\n", promedio_d))
Promedio de utilidades: 20015.01 soles
> cat(sprintf("Desviación estándar: %10.2f soles\n", desv_std_d))
Desviación estándar: 4510.64 soles
> cat(sprintf("Mediana: %10.2f soles\n", mediana_d))
Mediana: 19963.76 soles
> cat(sprintf("Mínimo: %10.2f soles\n", min_d))
Mínimo: 5293.20 soles
> cat(sprintf("Máximo: %10.2f soles\n", max_d))
Máximo: 37634.71 soles
>
> # Cuantiles adicionales
> cuantiles_d <- quantile(utilidades_20_maquinas, c(0.25, 0.5, 0.75, 0.9, 0.95))
> cat(sprintf("\nCuantiles de la distribución:\n"))

```

```

Cuantiles de la distribución:
> cat(sprintf("Q25: %.2f soles\n", cuantiles_d[1]))
Q25: 16878.40 soles
> cat(sprintf("Q50: %.2f soles\n", cuantiles_d[2]))
Q50: 19963.76 soles
> cat(sprintf("Q75: %.2f soles\n", cuantiles_d[3]))
Q75: 22971.34 soles
> cat(sprintf("Q90: %.2f soles\n", cuantiles_d[4]))
Q90: 25824.38 soles
> cat(sprintf("Q95: %.2f soles\n", cuantiles_d[5]))
Q95: 27629.17 soles
>
> # Verificación teórica
> utilidad_esperada_teorica_individual <- 1003.02 # Del inciso b
> utilidad_esperada_teorica_total <- n_maquinas_d * utilidad_esperada_teorica_individual
> cat(sprintf("\n--- VERIFICACIÓN TEÓRICA ---\n"))

--- VERIFICACIÓN TEÓRICA ---
> cat(sprintf("Utilidad esperada teórica (20 × %.2f): %.2f soles\n",
+           utilidad_esperada_teorica_individual, utilidad_esperada_teorica_total))
Utilidad esperada teórica (20 × 1003.02): 20060.40 soles
> cat(sprintf("Diferencia con simulación: %.2f soles (%.2f%%)\n",
+           promedio_d - utilidad_esperada_teorica_total,
+           (promedio_d - utilidad_esperada_teorica_total) / utilidad_esperada_teorica_total *
100))

```


Diferencia con simulación: -45.39 soles (-0.23%)

```

>
> # Histograma de resultados
> hist(utilidades_20_maquinas, breaks = 50,
+      col = "lightblue", border = "darkblue",
+      main = "Distribución de Utilidades (20 máquinas, 30 días, Poisson)",
+      xlab = "Utilidad total (soles)",
+      ylab = "Frecuencia")
> abline(v = promedio_d, col = "red", lwd = 3)
> abline(v = mediana_d, col = "orange", lwd = 2, lty = 2)
> legend("topright",
+       c("Media", "Mediana"),
+       col = c("red", "orange"),
+       lwd = c(3, 2), lty = c(1, 2))
> |

```

Distribución de Utilidades (20 máquinas, 30 días, Poisson)



Interpretación:

La simulación de 10,000 escenarios con 20 máquinas confirma la aplicación efectiva de los principios estadísticos fundamentales: la Ley de los Grandes Números se manifiesta en la consistencia entre el promedio simulado de 19,954.94 soles y el valor teórico esperado de 20,060.40 soles ($20 \times 1,003.02$), mientras que el Teorema del Límite Central explica la distribución aproximadamente normal de las utilidades totales. El análisis de variabilidad revela un coeficiente de variación del 22.05%, indicando un riesgo moderado y controlado, respaldado por la consistencia entre la desviación estándar observada (4,400.26 soles) y la teórica (4,430.87 soles). Desde la perspectiva empresarial, la utilidad esperada de aproximadamente 19,955 soles por lote con un intervalo de confianza del 95% entre [11,329, 28,581] soles y una utilidad mínima observada de 4,933 soles garantiza rentabilidad positiva en todos los escenarios. La significativa reducción del coeficiente de variación del 98.77% al 22.05% demuestra los beneficios de la diversificación, donde la

escala de operación con 20 máquinas mitiga sustancialmente el riesgo relativo y consolida la estabilidad financiera del negocio.

Conclusión:

La simulación de 20 máquinas confirma los beneficios de diversificación, con una utilidad esperada de aproximadamente 19,955 soles y variabilidad controlada, haciendo el negocio escalable y financieramente viable.

Inciso e:

Resultados de la simulación utilizando la nueva distribución de tiempos de falla. Se compara el cuantil 0.75 de la utilidad y el valor de t óptimo con el modelo de Poisson, evaluando si hay un cambio significativo. Además, se presenta un análisis comparativo de las medias y desviaciones estándar de ambas distribuciones de tiempos de falla.

```

> #=====
> #INCISO E Nueva distribución para tiempo hasta primera falla
> #=====
> cat("Implementación de nueva distribución de tiempo de falla\n")
Implementación de nueva distribución de tiempo de falla
> cat("f(t) = (8t/225) * exp(-4t²/225) para t > 0\n\n")
f(t) = (8t/225) * exp(-4t²/225) para t > 0

>
> # Función de densidad de la nueva distribución
> densidad_nueva <- function(t) {
+   if(t <= 0) return(0)
+   return((8 * t / 225) * exp(-4 * t^2 / 225))
+ }
>
> # Encontrar el máximo de la función de densidad para el método de rechazo
> # f'(t) = (8/225) * e^(-4t²/225) * [1 - (8t²/225)]
> # f'(t) = 0 cuando 1 - (8t²/225) = 0, es decir t = sqrt(225/8)
> t_max_densidad <- sqrt(225/8)
> f_max <- densidad_nueva(t_max_densidad)
>
> cat(sprintf("Análisis de la nueva distribución:\n"))
Análisis de la nueva distribución:
> cat(sprintf("Máximo de la densidad en t = %.3f días\n", t_max_densidad))
Máximo de la densidad en t = 5.303 días
> cat(sprintf("Valor máximo f(t*) = %.6f\n", f_max))
Valor máximo f(t*) = 0.114369
>
> # Implementación del método de rechazo para generar muestras
> generar_tiempo_nueva_distribucion <- function() {
+   # Método de rechazo con dominio amplio para capturar la cola
+   max_t <- 50 # Dominio suficiente ya que la función decrece rápidamente
+   repeat {

+       # Generar candidato uniformemente
+       t_candidato <- runif(1, 0, max_t)
+       u <- runif(1, 0, f_max * 1.05) # Pequeño margen de seguridad
+
+       # Evaluar función de densidad
+       f_t <- densidad_nueva(t_candidato)
+
+       # Aceptar o rechazar
+       if(u <= f_t) {
+         return(t_candidato)
+       }
+     }
+ }
>
> # Función para calcular utilidad con la nueva distribución
> calcular_utilidad_nueva_dist <- function(t) {
+   # Mismo modelo de costos que antes
+   ingresos <- 150 * t
+   costo_base <- 60 * t
+
+   # Generar tiempo hasta primera falla con la nueva distribución
+   tiempo_falla <- generar_tiempo_nueva_distribucion()
+
+   if(tiempo_falla <= t) {
+     # Hay falla dentro del período de contrato
+     dias_restantes <- t - tiempo_falla
+     costo_adicional <- 100 * dias_restantes
+     utilidad <- ingresos - costo_base - costo_adicional
+   } else {
+     # No hay falla durante el contrato
+     utilidad <- ingresos - costo_base
+   }
+
+   return(utilidad)
+ }
>
> # Recalcular cuantil 0.75 para t=30 con la nueva distribución

```

```

> n_sim_e <- 10000
> cat(sprintf("Calculando cuantil 0.75 con nueva distribución (%d simulaciones)...\n", n_sim_e))
Calculando cuantil 0.75 con nueva distribución (10000 simulaciones)...
> utilidades_30_nueva <- replicate(n_sim_e, calcular_utilidad_nueva_dist(30))
> cuantil_75_nueva <- quantile(utilidades_30_nueva, 0.75)
>
> # Búsqueda del nuevo t óptimo (búsqueda más limitada por eficiencia)
> utilidad_esperada_nueva <- function(t, n_sim = 1000) {
+   utilidades <- replicate(n_sim, calcular_utilidad_nueva_dist(t))
+   return(mean(utilidades))
+ }
>
> t_valores_nueva <- seq(10, 100, by = 5) # Búsqueda más espaciada
> cat("Buscando t óptimo con nueva distribución...\n")
Buscando t óptimo con nueva distribución...
> utilidades_nueva_dist <- numeric(length(t_valores_nueva))
>
> for(i in seq_along(t_valores_nueva)) {
+   utilidades_nueva_dist[i] <- utilidad_esperada_nueva(t_valores_nueva[i])
+   cat(sprintf("t = %3d días: %8.2f soles\n", t_valores_nueva[i], utilidades_nueva_dist[i]))
+ }
t = 10 días: 525.13 soles
t = 15 días: 536.29 soles
t = 20 días: 467.53 soles
t = 25 días: 431.84 soles
t = 30 días: 360.51 soles
t = 35 días: 307.11 soles
t = 40 días: 260.86 soles
t = 45 días: 217.04 soles
t = 50 días: 176.71 soles
t = 55 días: 93.89 soles
t = 60 días: 79.27 soles
t = 65 días: 3.40 soles
t = 70 días: -34.13 soles
t = 75 días: -96.05 soles
t = 80 días: -123.69 soles
t = 85 días: -183.89 soles
t = 90 días: -230.17 soles
t = 95 días: -286.49 soles
t = 100 días: -338.15 soles

```

```

t = 100 días: -338.15 soles
>
> t_optimo_nueva <- t_valores_nueva[which.max(utilidades_nueva_dist)]
> utilidad_maxima_nueva <- max(utilidades_nueva_dist)
>
> cat(sprintf("\n--- RESULTADOS PARTE E ---\n"))
--- RESULTADOS PARTE E ---
> cat(sprintf("PREGUNTA: ¿Cambiaría el tiempo óptimo y el cuantil 0.75 para t=30?\n"))
PREGUNTA: ¿Cambiaría el tiempo óptimo y el cuantil 0.75 para t=30?
> cat(sprintf("RESPUESTA:\n"))
RESPUESTA:
>
> # Comparación de cuantiles 0.75
> diferencia_cuantil <- cuantil_75_nueva - cuantil_75
> cambio_cuantil <- abs(diferencia_cuantil) > 10 # Cambio significativo si > 10 soles
>
> cat(sprintf("Cuantil 0.75 para t=30:\n"))
Cuantil 0.75 para t=30:
> cat(sprintf(" - Poisson: %8.2f soles\n", cuantil_75))
- Poisson: 1762.19 soles
> cat(sprintf(" - Nueva distribución: %8.2f soles\n", cuantil_75_nueva))
- Nueva distribución: 591.96 soles
> cat(sprintf(" - Diferencia: %+8.2f soles\n", diferencia_cuantil))
- Diferencia: -1170.23 soles
>
> if(cambio_cuantil) {
+   cat(sprintf(" - SI CAMBIA significativamente el cuantil 0.75\n"))
+ } else {
+   cat(sprintf(" - NO cambia significativamente el cuantil 0.75\n"))
+ }
- SI CAMBIA significativamente el cuantil 0.75
>
> # Comparación de t óptimo
> diferencia_t_optimo <- t_optimo_nueva - t_optimo
> cambio_t_optimo <- abs(diferencia_t_optimo) > 5 # Cambio significativo si > 5 días
>
> cat(sprintf("\nt óptimo:\n"))
t óptimo:
> cat(sprintf(" - Poisson: %8d días\n. t_optimo))

```

```

t_optimo:
> cat(sprintf(" - Poisson:           %8d días\n", t_optimo))
- Poisson:           35 días
> cat(sprintf(" - Nueva distribución: %8d días\n", t_optimo_nueva))
- Nueva distribución: 15 días
> cat(sprintf(" - Diferencia:         %+8d días\n", diferencia_t_optimo))
- Diferencia:         -20 días
>
> if(cambio_t_optimo) {
+   cat(sprintf(" - SI CAMBIA el tiempo óptimo de contrato\n"))
+ } else {
+   cat(sprintf(" - NO cambia el tiempo óptimo de contrato\n"))
+ }
- SI CAMBIA el tiempo óptimo de contrato
>
> cat(sprintf("\nCONCLUSION PARTE E:\n"))

CONCLUSION PARTE E:
> if(cambio_cuantil || cambio_t_optimo) {
+   cat("La objeción de cambiar el modelo de distribución SI tiene impacto en:\n")
+   if(cambio_cuantil) cat("- El cuantil 0.75 de la utilidad\n")
+   if(cambio_t_optimo) cat("- La duración óptima del contrato\n")
+ } else {
+   cat("La objeción de cambiar el modelo NO tiene impacto significativo\n")
+ }
La objeción de cambiar el modelo de distribución SI tiene impacto en:
- El cuantil 0.75 de la utilidad
- La duración óptima del contrato
>
> # Comparar características de las distribuciones
> n_comp <- 5000
> cat(sprintf("\nComparación de distribuciones de tiempos de falla (%d muestras):\n", n_comp))

Comparación de distribuciones de tiempos de falla (5000 muestras):
> tiempos_poisson <- replicate(n_comp, simular_tiempo_primera_falla(lambda))
> tiempos_nueva <- replicate(n_comp, generar_tiempo_nueva_distribucion())
>
> cat(sprintf("Distribución Exponencial (Poisson):\n"))

Distribución Exponencial (Poisson):
> cat(sprintf(" Media: %6.2f días, Mediana: %6.2f días, Desv.Std: %6.2f días\n",
+             mean(tiempos_poisson), median(tiempos_poisson), sd(tiempos_poisson)))
Media: 15.19 días, Mediana: 10.39 días, Desv.Std: 15.60 días
>
> cat(sprintf("Nueva distribución:\n"))
Nueva distribución:
> cat(sprintf(" Media: %6.2f días, Mediana: %6.2f días, Desv.Std: %6.2f días\n",
+             mean(tiempos_nueva), median(tiempos_nueva), sd(tiempos_nueva)))
Media: 6.65 días, Mediana: 6.19 días, Desv.Std: 3.41 días
> |

```

Environment

En esta etapa se incorporan funciones y resultados para la nueva distribución de tiempo hasta la primera falla. Objetos como `utilidades_30_nueva`, `cuantil_75_nueva` y `t_optimo_nueva` reflejan una comparación directa con el modelo de Poisson, aumentando la cantidad de información en el Environment. Este incremento en el contenido del entorno es natural, pues se añade un nuevo modelo estadístico que amplía el análisis y permite evaluar la sensibilidad de los resultados frente a cambios en la hipótesis de fallas, como se puede ver a continuación.

Environment	History	Connections	Tutorial	
   Import Dataset	 125 MiB		 List	
R	Global Environment			
Values				
cambio_cuantil	Named logi TRUE			
cambio_t_optimo	TRUE			
cuantil_75	Named num 1762			
cuantil_75_nueva	Named num 592			
cuantiles_d	Named num [1:5] 16878 19964 22971 25824 27629			
desv_std_d	4510.64429209812			
desviacion_b	990.457704950433			
diferencia_cuant...	Named num -1170			
diferencia_t_opt...	-20			
f_max	0.114368517994761			
fallas_individua...	num [1:12] 5 8 2 10 5 4 3 2 3 4 ...			
fallas_maquina	7			
i	19L			
idx_optimo	35L			
intervalos	Factor w/ 7 levels "(-Inf,0]","(0,500]",...: 5 ...			
lambda	0.0666666666666667			
lambda_dia	0.0666666666666667			
marca	""			
max_d	37634.706004782			
mediana_d	19963.7624023283			
min_d	5293.20402143224			
n_comp	5000			
n_maquinas_d	20			
n_sim_b	10000			
n_sim_d	10000			
n_sim_e	10000			
num_maquinas	12			
prob_sin_falla	0.135335283236613			
promedio_b	1001.70478567954			
promedio_d	20015.0149970892			
rango_analisis	int [1:7] 32 33 34 35 36 37 38			
t_b	30			

Environment	History	Connections	Tutorial
   Import Dataset  			
R	Global Environment		
t_b	30		
t_d	30		
t_max_densidad	5.30330085889911		
t_optimo	35L		
t_optimo_nueva	15		
t_values	int [1:200] 1 2 3 4 5 6 7 8 9 10 ...		
t_values_nueva	num [1:19] 10 15 20 25 30 35 40 45 50 55 ...		
tabla_intervalos	'table' int [1:7(1d)] 1764 2313 1711 1185 895 ...		
tiempo_total_dias	60		
tiempos_nueva	num [1:5000] 1.91 7.16 18.29 13.4 9.37 ...		
tiempos_poisson	num [1:5000] 32.7 10.92 4.83 1.9 38.12 ...		
total_fallas	58		
utilidad_esperad...	1003.02		
utilidad_esperad...	20060.4		
utilidad_maxima	1004.54204820339		
utilidad_maxima...	536.285094956169		
utilidad_sin_fal...	2700		
utilidades_20_ma...	num [1:10000] 18876 22855 17911 19744 15877 ...		
utilidades_30	num [1:10000] 1569.4 56.8 1041.1 -113.4 -207.9...		
utilidades_30_nu...	num [1:10000] 81.7 126.7 141.2 121.9 711.4 ...		
utilidades_esper...	num [1:200] 86.7 167.2 241.9 311.1 375.2 ...		
utilidades_nueva...	num [1:19] 525 536 468 432 361 ...		
valor_esperado_t...	48		
Functions			
calcular_utilida...	function (t)		
calcular_utilida...	function (t)		
calcular_utilida...	function (n_maquinas, t)		
calcular_utilida...	function (t)		
densidad_nueva	function (t)		
generar_tiempo_n...	function ()		
simular_fallas_m...	function (lambda, tiempo_total)		
simular_tiempo_p...	function (lambda)		
utilidad_esperad...	function (t, n_sim = 1000)		

Conclusión:

sigue una forma de Rayleigh escalada con moda en 5.3 días y menor variabilidad- reduce drásticamente el cuantil a 578.88 soles (67.2% menos) y el tiempo óptimo a apenas 10 días (71.4% menos). Este cambio fundamental se explica porque la nueva distribución presenta fallas más tempranas y concentradas alrededor de los 5-7 días, con una media de 6.58 días versus los 15.00 días del modelo exponencial, lo que obliga a la empresa a adoptar contratos sustancialmente más cortos y expectativas de utilidad mucho más conservadoras debido al mayor riesgo de fallas prematuras.

Inciso f:

Histogramas comparativos de las utilidades para 20 máquinas utilizando el modelo de Poisson (izquierda con barras azules) y la nueva distribución solicitada (derecha con barras rojas). Las líneas verticales representan las medias de cada caso. La comparación revela cómo la variabilidad y el promedio de las utilidades se ven alterados al cambiar la suposición del modelo de fallas.

```
> #=====
> #INCISO F
> #=====
>
> cat("Simulación de 20 máquinas con nueva distribución\n")
Simulación de 20 máquinas con nueva distribución
> cat("Comparación con resultados de distribución Poisson\n\n")
Comparación con resultados de distribución Poisson

>
> # Función para calcular utilidad total con la nueva distribución
> calcular_utilidad_total_nueva <- function(n_maquinas, t) {
+   utilidad_total <- 0
+   for(i in 1:n_maquinas) {
+     utilidad_total <- utilidad_total + calcular_utilidad_nueva_dist(t)
+   }
+   return(utilidad_total)
+ }
>
> # Simulación con nueva distribución (mismo número de simulaciones que parte D)
> n_sim_f <- 10000
> cat(sprintf("Realizando %d simulaciones con nueva distribución...\n", n_sim_f))
Realizando 10000 simulaciones con nueva distribución...
> utilidades_20_nueva <- replicate(n_sim_f, calcular_utilidad_total_nueva(20, 30))
>
> # Estadísticas descriptivas
> promedio_f <- mean(utilidades_20_nueva)
> desv_std_f <- sd(utilidades_20_nueva)
> mediana_f <- median(utilidades_20_nueva)
> min_f <- min(utilidades_20_nueva)
> max_f <- max(utilidades_20_nueva)
>
> cat(sprintf("\n--- RESULTADOS PARTE F ---\n"))
```

```

--- RESULTADOS PARTE F ---
> cat(sprintf("Nueva distribución - 20 máquinas, t=30 días:\n"))
Nueva distribución - 20 máquinas, t=30 días:
> cat(sprintf("Promedio de utilidades: %10.2f soles\n", promedio_f))
Promedio de utilidades: 7290.86 soles
> cat(sprintf("Desviación estándar: %10.2f soles\n", desv_std_f))
Desviación estándar: 1550.41 soles
> cat(sprintf("Mediana: %10.2f soles\n", mediana_f))
Mediana: 7251.51 soles
> cat(sprintf("Mínimo: %10.2f soles\n", min_f))
Mínimo: 2326.90 soles
> cat(sprintf("Máximo: %10.2f soles\n", max_f))
Máximo: 14454.20 soles
>
> # Comparación detallada entre ambas distribuciones
> diferencia_promedio <- promedio_f - promedio_d
> diferencia_std <- desv_std_f - desv_std_d
> diferencia_porcentual_promedio <- 100 * diferencia_promedio / promedio_d
> diferencia_porcentual_std <- 100 * diferencia_std / desv_std_d
>
> cat(sprintf("\n--- COMPARACIÓN ENTRE DISTRIBUCIONES ---\n"))

--- COMPARACIÓN ENTRE DISTRIBUCIONES ---
> cat(sprintf("Métrica Poisson Nueva Dist. Diferencia %%Cambio\n"))
Métrica Poisson Nueva Dist. Diferencia %%Cambio
> cat(sprintf("%-15s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Promedio", promedio_d, promedio_f, diferencia_promedio, diferencia_porcentual_promedio))
Promedio 20015.01 7290.86 -12724.15 -63.6%
> cat(sprintf("%-15s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Desv. Estándar", desv_std_d, desv_std_f, diferencia_std, diferencia_porcentual_std))
Desv. Estándar 4510.64 1550.41 -2960.23 -65.6%
> cat(sprintf("%-15s %12.2f %12.2f %12.2f %8.1f%%\n",
+ "Mediana", mediana_d, mediana_f, mediana_f - mediana_d,
+ 100 * (mediana_f - mediana_d) / mediana_d))
Mediana 19963.76 7251.51 -12712.25 -63.7%

```



```

> # Análisis estadístico adicional
> error_estandar_diff <- sqrt((desv_std_d^2 + desv_std_f^2) / n_sim_d)
> estadistico_t <- diferencia_promedio / error_estandar_diff
> p_valor_aprox <- 2 * (1 - pnorm(abs(estadistico_t)))
>
> cat(sprintf("\nAnálisis de significancia estadística:\n"))


Análisis de significancia estadística:
> cat(sprintf("Error estándar de la diferencia: %.2f\n", error_estandar_diff))
Error estándar de la diferencia: 47.70
> cat(sprintf("Estadístico t aproximado: %.3f\n", estadistico_t))
Estadístico t aproximado: -266.772
> cat(sprintf("p-valor aproximado: %.6f\n", p_valor_aprox))
p-valor aproximado: 0.000000
>
> if(p_valor_aprox < 0.001) {
+   cat("La diferencia es ALTAMENTE SIGNIFICATIVA (p < 0.001)\n")
+ } else if(p_valor_aprox < 0.01) {
+   cat("La diferencia es MUY SIGNIFICATIVA (p < 0.01)\n")
+ } else if(p_valor_aprox < 0.05) {
+   cat("La diferencia es SIGNIFICATIVA (p < 0.05)\n")
+ } else {
+   cat("La diferencia NO es estadísticamente significativa (p ≥ 0.05)\n")
+ }
La diferencia es ALTAMENTE SIGNIFICATIVA (p < 0.001)
>
> # Gráfico comparativo
> par(mfrow = c(1, 2))
>
> # Histograma Poisson
> hist(utilidades_20_maquinas, breaks = 50,
+      col = rgb(0, 0, 1, 0.5), border = "blue",
+      main = "Distribución Poisson\n(20 máquinas, 30 días)",
+      xlab = "Utilidad (soles)", ylab = "Frecuencia",
+      xlim = c(min(c(utilidades_20_maquinas, utilidades_20_nueva)),
+               max(c(utilidades_20_maquinas, utilidades_20_nueva))))
> abline(v = promedio_d, col = "blue", lwd = 3)
>

```

```

> # Histograma Nueva distribución
> hist(utilidades_20_nueva, breaks = 50,
+      col = rgb(1, 0, 0, 0.5), border = "red",
+      main = "Nueva Distribución\n(20 máquinas, 30 días)",
+      xlab = "Utilidad (soles)", ylab = "Frecuencia",
+      xlim = c(min(c(utilidades_20_maquinas, utilidades_20_nueva)),
+               max(c(utilidades_20_maquinas, utilidades_20_nueva))))
> abline(v = promedio_f, col = "red", lwd = 3)
>
> par(mfrow = c(1, 1))
>

```



Interpretación:

La simulación con 20 máquinas bajo la nueva distribución revela una reducción drástica en la utilidad promedio de 19,954.94 a 7,305.52 soles (63.4% menos), acompañada de una disminución similar en la variabilidad (desviación estándar de 4,400.26 a 1,565.40 soles, 64.9% menos), evidenciando que el modelo de fallas alternativo genera utilidades consistentemente más bajas pero con menor dispersión, lo que sugiere un patrón de fallas más predecible pero económicamente menos favorable debido a la mayor frecuencia de fallas tempranas que reducen significativamente la rentabilidad esperada del negocio a gran escala.

Conclusión:

La comparación entre ambos modelos demuestra que la elección de la distribución de fallas tiene un impacto determinante en la viabilidad financiera del negocio, donde la nueva distribución no sólo reduce sustancialmente las utilidades esperadas sino que también altera completamente la estrategia óptima de operación, confirmando que la objeción inicial sobre el modelo Poisson es fundamental y requiere un replanteamiento completo del modelo de negocio basado en una caracterización más precisa del comportamiento real de las fallas de las máquinas.