

1EST22 Probabilidad y Estadística

Modelo de Regresión Lineal

Prof. Cristian Bayes

FCI
2025

- 1 Introducción
- 2 Modelo de regresión lineal simple
 - Modelo de regresión lineal simple
 - Estimación
 - Covariable categórica
 - Inferencia
- 3 El modelo de regresión lineal múltiple
 - Modelo de regresión lineal múltiple
 - Estimación
 - Medidas para comparación de modelos
 - Covariable categórica
 - Inferencia

Motivación


- En un estudio de automóviles, se desea estudiar la relación entre la eficiencia en consumo de combustible medida en millas por galón (mpg) y la potencia del motor en caballos de fuerza (hp).
- Consideremos los datos disponibles en R en el objeto `mtcars`.

```
head(mtcars)
```

##	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
## Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
## Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
## Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
## Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
## Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
## Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

Motivación

```
plot(mtcars$hp,mtcars$mpg,pch=16)
```



```
cor(mtcars$hp,mtcars$mpg)
```

```
## [1] -0.7761684
```

- Observamos que existe evidencia de una asociación lineal negativa, es decir, que si la potencia del motor aumenta se observa que la eficiencia tiende a disminuir.
- Podemos medir esta tendencia mediante el coeficiente de correlación muestral de Pearson ($\hat{\rho}_{XY} = -0.776$), que en este caso indica que se tiene una fuerte asociación negativa.

Motivación

- Correlación lineal de Pearson (estimador):

$$\hat{\rho}_{xy} = \frac{S_{xy}}{S_x S_y}$$

- donde

$$S_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}, \quad S_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad \text{y} \quad S_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1}$$

- son estimadores de la covarianza, varianza de X y varianza de Y respectivamente.

Modelo de regresión lineal simple

- En el proceso de modelar se han definido dos tipos de variables
 - Variable respuesta: denotada por Y
 - Covariable: denotada por X
- En nuestro ejemplo, deseamos ver si la potencia del motor explica la eficiencia en consumo de combustible de un automóvil, por lo tanto,
 - Variable respuesta: eficiencia (Y)
 - Covariable: potencia del motor (X)

Modelo de regresión lineal simple

- El modelo de regresión lineal simple es dado por

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- donde ϵ es un error aleatorio que usualmente se asume satisface los siguientes supuestos clásicos:

$$(i) \quad E(\epsilon) = 0$$

$$(ii) \quad Var(\epsilon) = \sigma^2 \text{ (varianza constante)}$$

$$(iii) \quad cor(\epsilon_i, \epsilon_j) = 0, \quad \forall i \neq j \text{ (errores no correlacionados)}$$

- El modelo anterior lo podríamos también escribir mediante la recta de regresión:

$$y_x = E(Y \mid X = x) = \beta_0 + \beta_1 x \quad \text{y} \quad Var(Y \mid X = x) = \sigma^2$$

Modelo de regresión lineal simple

- Coeficientes de regresión: β_0, β_1
- **Intercepto:** β_0

$$y_0 = E(Y \mid X = 0) = \beta_0$$

- Interpretación: El valor esperado de Y cuando $X = 0$ (no siempre tiene una interpretación práctica).
- **Pendiente:** β_1

$$y_{x+1} - y_x = E(Y \mid X = x + 1) - E(Y \mid X = x) = \beta_1$$

- Interpretación: Si X aumenta en una unidad se espera que Y aumente (o disminuya) en β_1 unidades.
- En adelante asumiremos, que X es fijo o no aleatorio, por lo cual lo denotaremos en minúsculas. En este caso la esperanza condicional arriba es un esperado simple.

Estimación

- Dada una m.a. de Y para n valores dados de x : $(x_1, Y_1), \dots, (x_n, Y_n)$, el modelo anterior nos dice que:

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, \dots, n$$

- Se define la suma de cuadrados de los errores como:

$$SCE(\beta_0, \beta_1) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i)^2.$$

- Estimador de mínimos cuadrados ordinarios: Hallar β_0 y β_1 que minimicen la suma de cuadrados de los errores. Solución:

$$\hat{\beta}_1 = \hat{\rho}_{xY} \frac{S_Y}{S_x}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x},$$


donde $S_x = \sqrt{S_x^2}$ y $S_Y = \sqrt{S_Y^2}$.

Estimación

```
reg = lm(mpg~hp,mtcars)
reg
```

```
## Coefficients:
## (Intercept)          hp
##      30.09886      -0.06823
```

```
plot(mtcars$hp,mtcars$mpg,pch=16)
abline(reg,col="red",lwd=2)
```



- Recta estimada:

$$\hat{y}_x = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$= 30.09886 - 0.06823x$$

- Intercepto ($\hat{\beta}_0$): no tiene interpretación práctica en este caso.
- Pendiente ($\hat{\beta}_1$): Si la potencia del motor aumenta en un caballo de fuerza se espera que la eficiencia en consumo de combustible disminuya en 0.06823 millas por galón.

Estimación

- Valores observados: $y_i, i = 1, 2, \dots, n$
- Valores ajustados

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i, i = 1, 2, \dots, n$$

- Residuales

$$\hat{\epsilon}_i = y_i - \hat{y}_i, i = 1, 2, \dots, n$$

- Los residuales serán utilizados para verificar si se cumplen los supuestos del modelo.

Propiedades

- La suma de los residuales es igual a cero.

$$\sum_{i=1}^n \hat{\epsilon}_i = \sum_{i=1}^n (y_i - \hat{y}_i) = 0$$

- La suma de los valores observados es igual a la suma de los valores ajustados.

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$$

- La recta estimada pasa por el punto $(\bar{x}, \bar{y})$, es decir,

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

El coeficiente de determinación

- Se tiene la siguiente propiedad de descomposición de la variabilidad de la variable respuesta:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SCT} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SCR} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SCE}$$

- SCT : suma de cuadrados total, mide la variabilidad total de los valores observados.
- SCR : suma de cuadrados de la regresión, mide la variabilidad de los valores ajustados.
- SCE : suma de cuadrados de los residuales.

El coeficiente de determinación

- A partir de la última propiedad, se propone como medida de bondad de ajuste, al coeficiente de determinación observado, denotado por R^2 ,

$$R^2 = 1 - \frac{SCE}{SCT} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

- Interpretación: El $100R^2\%$ de la variabilidad de Y es explicada por el modelo lineal con x .

Ejemplo

```
reg = lm(mpg~hp,mtcars)
summary(reg)$r.squared
```

```
## [1] 0.6024373
```

- El modelo con covariable la potencia del motor explica el 60.24% de la variabilidad de la eficiencia.

Ejemplo

Considerando los datos `mtcars` de R, estime un modelo para estimar la eficiencia en consumo de combustible (`mpg`) en función del peso del automóvil en miles libras (`wt`).

- a) Interprete los coeficientes.
- b) Estime la eficiencia en consumo de combustible de un automóvil con un peso de 3 mil libras.
- c) Compare este modelo con el modelo anterior con covariable la potencia del motor ¿Qué modelo es mejor para estimar la eficiencia?

Covariable categórica

- Consideremos ahora como covariable al tipo de caja de cambio de cambio que posee un automóvil (am).
- Esta variable es categórica, cuenta con dos niveles: automática o mecánica.
- Para representar este tipo de variables se utiliza una variable indicadora,

$$X = \begin{cases} 1 & , \text{ si la caja de cambio es mecánica} \\ 0 & , \text{ si la caja de cambio es automática} \end{cases}$$

Covariable categórica

- Consideremos un modelo de regresión con esta covariable

$$Y = \beta_0 + \beta_1 X$$

- Intercepto:** β_0

$$y_0 = E(Y \mid X = 0) = \beta_0$$

- Interpretación: Es el valor esperado de eficiencia para un automóvil con caja de cambio automática.
- Pendiente:** β_1

$$y_1 - y_0 = E(Y \mid X = 1) - E(Y \mid X = 0) = \beta_1$$

- Interpretación: Se espera que la eficiencia de un automóvil con caja de cambio mecánica tenga una eficiencia mayor (o menor) en β_1 unidades a la de un automóvil con caja de cambio automática.

Covariable categórica

```
reg = lm(mpg~am,mtcars)
reg
```

```
## Coefficients:
## (Intercept)          am
##      17.147      7.245
```

```
summary(reg)$r.squared
```

```
## [1] 0.3597989
```

```
# Observación:
# R estimará una covariable como categórica
# si está declarada como factor o si está
# definida como previamente como binaria
# (solo toma valores 0 y 1).
# En el ejemplo la variable está definida
# como binaria.
# is.factor(): indica si una variable es un
# factor.
# as.factor(): declara una variable como
# factor.
```

- Se espera que la eficiencia de un automóvil con caja de cambio automática sea de 17.1 millas por galón.
- Se espera que un automóvil con caja de cambio mecánica tenga una eficiencia mayor en 7.2 millas por galón a la eficiencia de un automóvil con caja automática.
- El modelo con covariable tipo de caja de cambio explica el 35.98% de la variabilidad de la eficiencia.

Estimación de σ^2

- También podemos estimar la varianza de los errores, σ^2 , en este caso el estimador es dado por

$$\hat{\sigma}^2 = \frac{SCE}{n-2} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2}$$

- Este, que se obtiene por máxima verosimilitud, es un estimador insesgado de la varianza en caso de normalidad.

Inferencia

- Para realizar inferencia se hace el supuesto adicional que los errores tienen distribución normal y son independientes entre sí:

$$\epsilon_i \stackrel{ind}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n$$

- A partir de este supuesto, tenemos el siguiente resultado

$$T = \frac{\hat{\beta}_j - \beta_j}{\widehat{EE}(\hat{\beta}_j)} \sim t(n-2), \quad j = 0, 1$$

donde el error estándar de $\hat{\beta}_j$ estimado $\widehat{EE}(\hat{\beta}_j)$ se define como

$$\widehat{EE}(\hat{\beta}_0) = \hat{\sigma} \left(\frac{1}{n} + \frac{\bar{x}}{S_{xx}} \right)^{1/2} \quad \text{y} \quad \widehat{EE}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{S_{xx}}}$$

con $S_{xx} = \sum_{i=1}^x (x_i - \bar{x})^2 = (n-1)S_x^2$.

Inferencia

Intervalo de confianza para un coeficiente de regresión

Un intervalo de confianza de nivel $100(1 - \alpha)\%$ para β_j ($j = 0, 1$) es dado por

$$IC(\beta_j) = [\hat{\beta}_j - t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{\beta}_j), \hat{\beta}_j + t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{\beta}_j)]$$

Prueba de hipótesis para un coeficiente de regresión

Hipótesis nula: $H_0 : \beta_j = \beta_{j0}$

Estadística de prueba	H_1	Región crítica	valor - p
$T = \frac{\hat{\beta}_j - \beta_{j0}}{\widehat{EE}(\hat{\beta}_j)} \sim t(n-2)$	$\beta_j \neq \beta_{j0}$ $\beta_j > \beta_{j0}$ $\beta_j < \beta_{j0}$	$ T > t_{1-\frac{\alpha}{2}}(n-2)$ $T > t_{1-\alpha}(n-2)$ $T < t_{\alpha}(n-2)$	$2P(T > T_{obs})$ $P(T > T_{obs})$ $P(T < T_{obs})$

Ejemplo

```
reg = lm(mpg~am,mtcars)
summary(reg)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   17.147      1.125   15.247 1.13e-15 ***
## am             7.245      1.764    4.106 0.000285 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.902 on 30 degrees of freedom
## Multiple R-squared:  0.3598, Adjusted R-squared:  0.3385
## F-statistic: 16.86 on 1 and 30 DF,  p-value: 0.000285
```

- $\hat{\beta}_0 = 17.147$, $\widehat{EE}(\hat{\beta}_0) = 1.125$.
- $\hat{\beta}_1 = 7.245$, $\widehat{EE}(\hat{\beta}_1) = 1.764$.
- Grados de libertad: $n - 2 = 30$
- Con estas estimaciones se pueden construir los IC para los coeficientes de regresión.

Ejemplo

- Cuantil t-Student: $t_{0.975}(30) = 2.042$

```
qt(0.975,30)
```

```
## [1] 2.042272
```

- IC al 95% para el intercepto:

$$\begin{aligned} IC(\beta_0) &= [\hat{\beta}_0 - t_{0.975}(30)\widehat{EE}(\hat{\beta}_0) , \hat{\beta}_0 + t_{0.975}(30)\widehat{EE}(\hat{\beta}_0)] \\ &= [7.245 - 2.042 \times 1.764 , 7.245 + 2.042 \times 1.764] \\ &= [14.85 , 19.44] \end{aligned}$$

- IC al 95% para la pendiente:

$$\begin{aligned} IC(\beta_1) &= [\hat{\beta}_1 - t_{0.975}(30)\widehat{EE}(\hat{\beta}_1) , \hat{\beta}_1 + t_{0.975}(30)\widehat{EE}(\hat{\beta}_1)] \\ &= [17.147 - 2.042 \times 1.125 , 17.147 + 2.042 \times 1.125] \\ &= [3.64 , 10.85] \end{aligned}$$

Ejemplo

```
confint(reg, level=0.95)
```

```
##                2.5 %    97.5 %  
## (Intercept) 14.85062 19.44411  
## am          3.64151 10.84837
```

- $IC(\beta_0) = [14.85, 19.44]$
- Interpretación: Con un 95% de confianza se puede afirmar que la eficiencia esperada de un automóvil con caja automática estará entre 14.85 y 19.44 mpg.
- $IC(\beta_1) = [3.64, 10.85]$
- Interpretación: Con un 95% de confianza se puede afirmar que la diferencia esperada en eficiencia entre un automóvil con caja mecánica y uno con caja automática estará entre 3.64 y 10.85 mpg.

Prueba de significancia de la regresión

- Hipótesis: $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$
- Si no se rechaza H_0 , implica que no existe una relación lineal entre x e y .
- Estadística de prueba:

$$T = \frac{\hat{\beta}_1}{\widehat{EE}(\hat{\beta}_1)} \sim t(n-2)$$

- Regla de decisión:

Rechazar H_0 : si $|T_{obs}| > t_{1-\frac{\alpha}{2}}(n-2) \Leftrightarrow \text{valor-p} = 2P(T > |T_{obs}|) < \alpha$

Ejemplo:

- Hipótesis: $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$
- No rechazar H_0 implicaría que no existe diferencias en eficiencia entre un auto con caja automática y uno con caja mecánica.
- Estadística de prueba

$$T_{obs} = \frac{\hat{\beta}_1}{\hat{E}E(\hat{\beta}_1)} = \frac{7.245}{1.764} = 4.106$$

- valor-p:

$$valor - p = P(T > 4.106) = 0.000285$$

- Para $\alpha = 0.05$, se rechaza H_0 . Por lo tanto, se puede afirmar que existe un efecto significativo del tipo de caja de cambio en la eficiencia esperada.
- En este caso, también podríamos decir que existe suficiente evidencia para afirmar que la eficiencia media de un automóvil con caja de cambio automática es diferente a la de un automóvil con caja de cambio mecánica.

Ejemplo

```
reg = lm(mpg~am,mtcars)
summary(reg)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   17.147      1.125   15.247 1.13e-15 ***
## am              7.245      1.764    4.106 0.000285 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.902 on 30 degrees of freedom
## Multiple R-squared:  0.3598, Adjusted R-squared:  0.3385
## F-statistic: 16.86 on 1 and 30 DF,  p-value: 0.000285
```

- De la salida en R, podemos observar que la información para realizar la prueba de hipótesis de significancia de la regresión se encuentra disponible en la fila `am` de la sección `Coefficients`.
- Con la información disponible en la salida se pueden realizar otras pruebas de hipótesis de ser necesarias.

Intervalo de confianza para la respuesta media

- Respuesta media para un nivel x_0 de la covariable:

$$y_{x_0} = E(Y \mid X = x_0)$$

- Estimador puntual:

$$\hat{y}_{x_0} = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

- Error estándar de estimación estimado:

$$\widehat{EE}(\hat{y}_{x_0}) = \hat{\sigma} \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]^{1/2}$$

$$\text{con } S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = (n-1)S_x^2$$

- Intervalo de confianza

$$IC(y_{x_0}) = [\hat{y}_{x_0} - t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{y}_{x_0}), \hat{y}_{x_0} + t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{y}_{x_0})]$$

Intervalo de predicción

- Respuesta (no media) para un nivel x_0 de la covariable: $y(x_0)$
- Error estándar de estimación estimado:

$$\widehat{EE}(\hat{y}(x_0)) = \hat{\sigma} \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]^{1/2}$$

$$\text{con } S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = (n-1)S_x^2$$

- Intervalo de predicción

$$IC(y(x_0)) = [\hat{y}_{x_0} - t_{1-\frac{\alpha}{2}}(n-2) \widehat{EE}(\hat{y}(x_0)), \hat{y}_{x_0} + t_{1-\frac{\alpha}{2}}(n-2) \widehat{EE}(\hat{y}(x_0))]$$

Ejemplo

- Estimar un IC al 95% para la eficiencia media de los automóviles con caja de cambio mecánica.
- Estimación puntual:

$$\hat{y}_1 = \hat{\beta}_0 + \hat{\beta}_1 \times 1 = 24.39231$$

- Error estándar de estimación estimado:

$$\widehat{EE}(\hat{y}_1) = \hat{\sigma} \left[\frac{1}{n} + \frac{(1 - \bar{x})^2}{S_{xx}} \right]^{1/2} = 4.902 \left[\frac{1}{32} + \frac{(1 - 0.406)^2}{7.718} \right]^{1/2} = 1.359$$

- Intervalo de confianza

$$\begin{aligned} IC(y_1) &= [\hat{y}_1 - t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{y}_1), \hat{y}_1 + t_{1-\frac{\alpha}{2}}(n-2)\widehat{EE}(\hat{y}_1)] \\ &= [24.392 - 2.042 \times 1.359, 24.392 + 2.042 \times 1.359] = [21.615, 27.168] \end{aligned}$$

Ejemplo

```
# Estimar regresión; retirar coeficientes; covariable
reg = lm(mpg~am,mtcars); b = coef(reg); x = mtcars$am
# IC
x0      = 1
(mu_hat = b[1]+b[2]*x0)
```

```
## [1] 24.39231
```

```
sigma    = summary(reg)$sigma
n        = nrow(mtcars)
s_xx     = sum((x-mean(x))**2)
(EE      = sigma*sqrt(1/n+(x0-mean(x))**2/s_xx))
```

```
## [1] 1.359578
```

```
(t       = qt(0.975,n-2))
```

```
## [1] 2.042272
```

```
(IC      = c(LI=mu_hat-t*EE,LS=mu_hat+t*EE))
```

```
##          LI          LS
## 21.61568 27.16894
```


Ejemplo

```
reg = lm(mpg~am,mtcars)
predict(reg,data.frame(am=1),interval="confidence")
```

```
##           fit      lwr      upr
## 1 24.39231 21.61568 27.16894
```

- Con un 95% de confianza la eficiencia media de los automóviles con caja de cambio mecánica estará entre 21.6 y 27.1 mpg.

Ejemplo

- Estimar un intervalo de predicción al 95% para la eficiencia de un automóvil con caja de cambio mecánica.
- Estimador puntual:

$$\hat{y}_1 = \hat{\beta}_0 + \hat{\beta}_1 \times 1 = 24.39231$$

- Error estándar:

$$\widehat{EE}(\hat{y}(1)) = \hat{\sigma} \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}} \right]^{1/2} = 4.902 \left[1 + \frac{1}{32} + \frac{(1 - 0.406)^2}{7.718} \right]^{1/2} = 5.08$$

- Intervalo de predicción

$$IC(y_1) = \hat{y}_1 \mp t_{1-\frac{\alpha}{2}}(30) \widehat{EE}(\hat{y}(1)) = 24.392 \mp 2.042 \times 5.08 = [14.0, 34.7]$$

Ejemplo

```
# Estimar regresión; retirar coeficientes; covariable
names(b) = NULL
# IC
x0      = 1
(mu_hat = b[1]+b[2]*x0)
```

```
## [1] 24.39231
```

```
sigma    = summary(reg)$sigma
n        = nrow(mtcars)
s_xx     = sum((x-mean(x))**2)
(EE      = sigma*sqrt(1+1/n+(x0-mean(x))**2/s_xx))
```

```
## [1] 5.087076
```

```
(t      = qt(0.975,n-2))
```

```
## [1] 2.042272
```

```
(IC      = c(LI=mu_hat-t*EE,LS=mu_hat+t*EE))
```

```
##      LI      LS
## 14.00311 34.78150
```


Ejemplo

```
reg = lm(mpg~am,mtcars)
predict(reg,data.frame(am=1),interval="predict")
```

```
##           fit      lwr      upr
## 1 24.39231 14.00311 34.7815
```

- Con un 95% de confianza la eficiencia de un automóvil con caja de cambio mecánica estará entre 14.0 y 34.8 mpg.

Ejemplo



Modelo de regresión lineal múltiple

- El modelo de regresión lineal múltiple es dado por

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon \quad (1)$$

- donde ϵ es un error aleatorio que usualmente se asume los supuestos clásicos.
- El modelo se puede también escribir como

$$y_{x_1 x_2, \dots, x_k} = E(Y \mid X_1 = x_1, \dots, X_k = x_k) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k \quad (2)$$

$$Var(Y \mid X_1 = x_1, \dots, X_k = x_k) = \sigma^2.$$

donde podríamos omitir la condicional, si es que asumimos que las covariables son fijas (no aleatorias).

Consideremos, para ilustrar, un modelo con $k = 2$ covariables. Entonces

- **Intercepto:** β_0

$$y_{00} = E(Y \mid X_1 = 0, X_2 = 0) = \beta_0$$

- Interpretación: Es el valor esperado de Y cuando $X_1 = 0$ y $X_2 = 0$ (no siempre tiene una interpretación práctica).
- **Coeficiente** β_1

$$y_{x+1,z} - y_{x,z} = E(Y \mid X_1 = x + 1, X_2 = z) - E(Y \mid X_1 = x, X_2 = z) = \beta_1$$

- Interpretación: Se espera que Y aumente (o disminuya) en β_1 unidades cuando X_1 aumenta en una unidad y X_2 permanece constante.
- **Coeficiente** β_2

$$y_{x,z+1} - y_{x,z} = E(Y \mid X_1 = x, X_2 = z + 1) - E(Y \mid X_1 = x, X_2 = z) = \beta_2$$

- Interpretación: Se espera que Y aumente (o disminuya) en β_2 unidades cuando X_2 aumenta en una unidad y X_1 permanece constante.

Estimación

- En adelante asumiremos que las covariables o variable independientes serán fijas (no aleatorias). Así, dada una m.a de Y para valores de las variables independientes $(x_{11}, \dots, x_{1k}, Y_1), \dots, (x_{n1}, \dots, x_{nk}, Y_n)$, estos deben seguir el modelo:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \epsilon_i, \quad i = 1, \dots, n \quad (3)$$

- Suma de cuadrados de los errores:

$$SCE(\beta_0, \beta_1, \dots, \beta_p) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2.$$

- Estimador de mínimos cuadrados ordinarios: Hallar $\beta_0, \beta_1, \dots, \beta_k$ que minimicen la suma de cuadrados de los errores.

Estimación

Podemos reescribir el modelo (3) de manera matricial como:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

donde

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{bmatrix}, \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}, \boldsymbol{\epsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Estimación

- Suma de cuadrados de los errores:

$$SCE(\beta) = \sum_{i=1}^n \epsilon_i^2 = \epsilon^\top \epsilon = (\mathbf{Y} - \mathbf{X}\beta)^\top (\mathbf{Y} - \mathbf{X}\beta)$$

- Estimador de mínimos cuadrados ordinarios

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

Estimación

```
reg = lm(mpg~hp+wt,mtcars)
reg
```

```
## Coefficients:
```

```
## (Intercept)          hp          wt
##    37.22727    -0.03177    -3.87783
```

- Modelo estimado:

$$\hat{y}_{x_1x_2} = \hat{\beta}_0 + \hat{\beta}_1x_1 + \hat{\beta}_2x_2 = 37.2 - 0.03x_1 - 3.9x_2$$

- Intercepto ($\hat{\beta}_0$): No tiene interpretación practica en este caso.
- Coeficiente ($\hat{\beta}_1$): Se estima que la eficiencia media en consumo de combustible disminuya en 0.03 millas por galón cuando la potencia del motor aumenta en un caballo de fuerza y el peso se mantiene constante.
- Coeficiente ($\hat{\beta}_2$): Se estima que la eficiencia media en consumo de combustible disminuya en 3.9 millas por galón cuando el peso aumenta en mil libras y la potencia del motor se mantiene constante.

Estimación

- Valores observados: $y_i, i = 1, 2, \dots, n$
- Valores ajustados

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ik}, \quad i = 1, 2, \dots, n$$

- Residuales

$$\hat{\epsilon}_i = y_i - \hat{y}_i, \quad i = 1, 2, \dots, n$$

- Los residuales serán utilizados para verificar si se cumplen los supuestos del modelo.

Medidas para comparación de modelos

- Coeficiente de determinación: R^2
- Coeficiente de determinación ajustado: R_{adj}^2
- Criterio de información de Akaike: AIC

Coefficiente de determinación

- Coeficiente de determinación, denotado por R^2 ,

$$R^2 = 1 - \frac{SCE}{SCT} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

- Interpretación: El $100R^2\%$ de la variabilidad de y es explicada por el modelo.
- Esta medida observada siempre disminuye a medida que se aumentan variables al modelo, aunque estas sean irrelevantes. Por esta razón, no se suele usar para comparación de modelos y se prefieren otras como medidas como el R^2 ajustado o el AIC.

Coefficiente de determinación ajustado

- Coeficiente de determinación ajustado, denotado por R_{adj}^2 ,

$$R_{adj}^2 = 1 - \frac{SCE/(n-p)}{SCT/(n-1)} = 1 - (1 - R^2) \frac{n-1}{n-p}$$

- donde $p = k + 1$, es el número de coeficientes de regresión del modelo, incluyendo el intercepto.
- Interpretación: El $100R_{adj}^2\%$ de la variabilidad de y es explicada por el modelo.
- El R_{adj}^2 solamente aumentará si se adiciona una covariable que explique la respuesta e incluso disminuirá en caso se adicione una variable irrelevante.

Criterio de información de Akaike

- Criterio de información de Akaike: AIC

$$AIC = -2\hat{\ell} + 2r$$

- donde $\hat{\ell}$ es la log-verosimilitud estimada y r es el número de parámetros.
- Considerando un modelo normal ($\epsilon_i \sim N(0, \sigma^2)$), tendríamos $p + 1$ parámetros y se obtiene

$$AIC = n \log(2\pi) + n + n \log(SCE/(n - p)) + 2(p + 1)$$

- A menor valor del AIC se obtiene un mejor ajuste.

Ejemplo

```
reg = lm(mpg~hp+wt,mtcars)
summary(reg)$r.squared
```

```
## [1] 0.8267855
```

```
AIC(reg)
```

```
## [1] 156.6523
```

- El modelo con covariables la potencia del motor y el peso del vehículo explica el 82.7% de la variabilidad de la eficiencia.
- El AIC no tiene una interpretación directa, se utiliza para comparar entre modelos.

Ejemplo

Considerando los datos `mtcars` de R, estime un modelo para estimar la eficiencia en consumo de combustible (`mpg`) en función del peso del automóvil en miles libras (`wt`) y del tipo de motor (`am`).

- a) Interprete los coeficientes.
- b) Estime la eficiencia en consumo de combustible de un automóvil con un peso de 3 mil libras y con motor mecánico.
- c) Compare este modelo con el modelo anterior ¿Qué modelo es mejor para estimar la eficiencia?

Covariable categórica con más de dos niveles

- Consideremos ahora como covariable al número de cilindros del motor (`cyl`).
- Esta variable se considera como categórica, cuenta con tres niveles: motor con 4 cilindros (`cyl=4`), motor con 6 cilindros (`cyl=6`) y motor con 8 cilindros (`cyl=8`).
- Para representar una variable cualitativa con dos categorías usamos una variable auxiliar. En el caso de tener s categorías requerimos de $s - 1$ variables auxiliares.
- Una de las categorías será denominada de referencia y se definiran las variables auxiliares como indicadores de las otras categorías.

Variable auxiliares

- En el ejemplo, tenemos 3 categorías, por lo tanto, se requieren 2 variables auxiliares.
- Consideremos como categoría de referencia tener un motor de 4 cilindros ($cy1=4$), por lo tanto, las variables auxiliares se definen como

$$x_1 = \begin{cases} 1 & , \text{ si el motor es de 6 cilindros} \\ 0 & , \text{ si de otro modo} \end{cases}$$

$$x_2 = \begin{cases} 1 & , \text{ si el motor es de 8 cilindros} \\ 0 & , \text{ si de otro modo} \end{cases}$$

Covariable categórica

- Consideremos un modelo de regresión con esta covariable

$$y_{x_1x_2} = \beta_0 + \beta_1x_1 + \beta_2x_2$$

- Notemos que

Categoría	Modelo estimado	
Motor de 4 cilindros	$\hat{y}_{00}$	$= \hat{\beta}_0$
Motor de 6 cilindros	$\hat{y}_{10}$	$= \hat{\beta}_0 + \hat{\beta}_1$
Motor de 8 cilindros	$\hat{y}_{01}$	$= \hat{\beta}_0 + \hat{\beta}_2$

Covariable categórica

Interpretación:

- $\hat{\beta}_0$, representa la eficiencia esperada estimada de un auto con un motor de 4 cilindros (categoría de referencia).
- $\hat{\beta}_1$, representa la diferencia esperada estimada entre la eficiencia de un auto con un motor de 6 cilindros contra uno que tenga un motor de 4 cilindros.
- $\hat{\beta}_2$, representa la diferencia esperada estimada entre la eficiencia de un auto con un motor de 8 cilindros contra uno que tenga un motor de 4 cilindros.

Covariable categórica

```
# Declaramos como factor cyl
mtcars$cyl = as.factor(mtcars$cyl)
reg = lm(mpg~cyl,mtcars)
reg
```

```
## Coefficients:
## (Intercept)      cyl6      cyl8
##      26.664      -6.921     -11.564
```

```
summary(reg)$adj.r.squared
```

```
## [1] 0.714009
```

```
# Observación:
# is.factor(): indica si una variable es un
#               factor.
# as.factor(): declara una variable como
#               factor.
```

- Se espera que la eficiencia de un automóvil con un motor de 4 cilindros sea de 26.7 millas por galón.
- Se espera que un automóvil con un motor de 6 cilindros tenga una eficiencia menor en 6.9 millas por galón a la eficiencia de un automóvil con un motor de 4 cilindros.
- Se espera que un automóvil con un motor de 8 cilindros tenga una eficiencia menor en 11.6 millas por galón a la eficiencia de un automóvil con un motor de 4 cilindros.
- El modelo con covariable el número de cilindros del motor explica el 71.4% de la variabilidad de la eficiencia.

Estimación de σ^2

- También podemos estimar la varianza de los errores, σ^2 , en este caso el estimador es dado por

$$\hat{\sigma}^2 = \frac{SCE}{n - p} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n - p}$$

- Este es un estimador insesgado de la varianza.

Inferencia

- Para realizar inferencia se hace el supuesto adicional que los errores tienen distribución normal y son independientes entre sí:

$$\epsilon_i \stackrel{ind}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n$$

- Se obtiene que la matriz de covarianza estimada de los coeficientes es

$$\widehat{\text{cov}}(\hat{\beta}) = \begin{bmatrix} \widehat{\text{var}}(\hat{\beta}_0) & \widehat{\text{cov}}(\hat{\beta}_0, \hat{\beta}_1) & \cdots & \widehat{\text{cov}}(\hat{\beta}_0, \hat{\beta}_k) \\ \widehat{\text{cov}}(\hat{\beta}_0, \hat{\beta}_1) & \widehat{\text{var}}(\hat{\beta}_1) & \cdots & \widehat{\text{cov}}(\hat{\beta}_1, \hat{\beta}_k) \\ \vdots & \vdots & \ddots & \vdots \\ \widehat{\text{cov}}(\hat{\beta}_0, \hat{\beta}_k) & \widehat{\text{cov}}(\hat{\beta}_1, \hat{\beta}_k) & \cdots & \widehat{\text{var}}(\hat{\beta}_k) \end{bmatrix} = \hat{\sigma}^2 (\mathbf{X}^\top \mathbf{X})^{-1}$$

- Por lo tanto, el error estándar del estimador estimado de un coeficiente $\hat{\beta}_j$, será

$$\widehat{EE}(\hat{\beta}_j) = \sqrt{\widehat{\text{var}}(\hat{\beta}_j)} = \hat{\sigma} \sqrt{c_{jj}}$$

- donde c_{jj} está en la diagonal $j+1$ de la matriz $(\mathbf{X}^\top \mathbf{X})^{-1}$.

Inferencia

- Tenemos el siguiente resultado

$$T = \frac{\hat{\beta}_j - \beta_j}{\widehat{EE}(\hat{\beta}_j)} \sim t(n - p), \quad j = 0, 1, \dots, k$$

Inferencia

Intervalo de confianza para un coeficiente de regresión

Un intervalo de confianza de nivel $100(1 - \alpha)\%$ para β_j ($j = 0, 1, \dots, k$) es dado por

$$IC(\beta_j) = [\hat{\beta}_j - t_{1-\frac{\alpha}{2}}(n-p)\widehat{EE}(\hat{\beta}_j), \hat{\beta}_j + t_{1-\frac{\alpha}{2}}(n-p)\widehat{EE}(\hat{\beta}_j)]$$

Prueba de hipótesis para un coeficiente de regresión

Hipótesis nula: $H_0 : \beta_j = \beta_{j0}$

Estadística de prueba	H_1	Región crítica	valor-p
$T = \frac{\hat{\beta}_j - \beta_{j0}}{\widehat{EE}(\hat{\beta}_j)} \sim t(n-p)$	$\beta_j \neq \beta_{j0}$ $\beta_j > \beta_{j0}$ $\beta_j < \beta_{j0}$	$ T > t_{1-\frac{\alpha}{2}}(n-p)$ $T > t_{1-\alpha}(n-p)$ $T < t_{\alpha}(n-p)$	$2P(T > T_{obs})$ $P(T > T_{obs})$ $P(T < T_{obs})$

Ejemplo

```
reg = lm(mpg~hp+wt,mtcars)
summary(reg)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 37.22727      1.59879   23.285 < 2e-16 ***
## hp          -0.03177      0.00903   -3.519  0.00145 **
## wt          -3.87783      0.63273   -6.129  1.12e-06 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.593 on 29 degrees of freedom
## Multiple R-squared:  0.8268, Adjusted R-squared:  0.8148
## F-statistic: 69.21 on 2 and 29 DF,  p-value: 9.109e-12
```

- $\hat{\beta}_0 = 37.227$, $\widehat{EE}(\hat{\beta}_0) = 1.599$.
- $\hat{\beta}_1 = -0.031$, $\widehat{EE}(\hat{\beta}_1) = 0.009$.
- $\hat{\beta}_2 = -3.878$, $\widehat{EE}(\hat{\beta}_2) = 0.633$.
- Grados de libertad: $n - p = 32 - 3 = 29$
- Con estas estimaciones se pueden construir los IC para los coeficientes de regresión.

Ejemplo

- Cuantil t-Student: $t_{0.975}(29) = 2.045$

```
qt(0.975,29)
```

```
## [1] 2.04523
```

- IC al 95% para el intercepto:

$$\begin{aligned} IC(\beta_0) &= [\hat{\beta}_0 - t_{0.975}(29)\hat{EE}(\hat{\beta}_0) , \hat{\beta}_0 + t_{0.975}(29)\hat{EE}(\hat{\beta}_0)] \\ &= [37.227 - 2.045 \times 1.599 , 37.227 + 2.045 \times 1.599] \\ &= [33.96, 40.50] \end{aligned}$$

- IC al 95% para β_1 :

$$\begin{aligned} IC(\beta_1) &= [\hat{\beta}_1 - t_{0.975}(29)\hat{EE}(\hat{\beta}_1) , \hat{\beta}_1 + t_{0.975}(29)\hat{EE}(\hat{\beta}_1)] \\ &= [-0.031 - 2.045 \times 0.009 , -0.031 + 2.045 \times 0.009] \\ &= [-0.050, -0.013] \end{aligned}$$

Ejemplo

- IC al 95% para β_2 :

$$\begin{aligned} IC(\beta_2) &= [\hat{\beta}_1 - t_{0.975}(29)\hat{E}E(\hat{\beta}_1) , \hat{\beta}_1 + t_{0.975}(29)\hat{E}E(\hat{\beta}_1)] \\ &= [-3.878 - 2.045 \times 0.633 , -3.878 - 2.045 \times 0.633] \\ &= [-5.17, -2.58] \end{aligned}$$

Ejemplo

```
confint(reg, level=0.95)
```

```
##                2.5 %      97.5 %  
## (Intercept) 33.95738245 40.49715778  
## hp          -0.05024078 -0.01330512  
## wt          -5.17191604 -2.58374544
```

- $IC(\beta_0) = [33.96, 40.50]$ (no tiene interpretación práctica)
- $IC(\beta_1) = [-0.050, -0.013]$
- Interpretación: Con un 95% de confianza se puede afirmar que la disminución esperada en eficiencia cuando se aumenta en 1 caballo de fuerza la potencia del motor estará entre 0.013 y 0.050 mpg, cuando las demás variables permanecen constantes.
- $IC(\beta_2) = [-5.17, -2.58]$
- Interpretación: Con un 95% de confianza se puede afirmar que la disminución esperada en eficiencia cuando se aumenta en mil libras el peso de un automóvil estará entre 2.58 y 5.17 mpg, cuando las demás variables permanecen constantes.

Prueba de significancia de la regresión

- Hipótesis:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1 : \text{al menos un } \beta_j \neq 0$$

- Si no se rechaza H_0 , implica que no existe una relación lineal entre las covariables y la variable respuesta.
- Estadística de prueba:

$$F = \frac{SCR/p}{SCE/(n-p)} = \frac{R^2}{1-R^2} \times \frac{n-p}{p} \sim F_{p,n-p}$$

- Regla de decisión:

$$\text{Rechazar } H_0 : \text{ si } |F_{obs}| > F_{1-\alpha} \Leftrightarrow \text{valor-p} = P(F > F_{obs}) < \alpha$$

- $F_{p,n-p}$ denota a la distribución F de Fisher con grados de libertad de numerador p y grados de libertad del denominador $n-p$.

Ejemplo:

- Modelo: covariable: número de cilindros.
- Hipótesis: $H_0 : \beta_1 = \beta_2 = 0$ vs $H_1 : \text{al menos un } \beta_j \neq 0$
- No rechazar H_0 implicaría que no existe diferencias en eficiencia entre un auto con un motor de 4, 6 o 8 cilindros.
- Estadística de prueba

$$F_{obs} = \frac{0.7325}{1 - 0.7325} \times \frac{29}{2} = 39.7$$

- valor-p:

$$valor - p = P(F > 39.7) = 4.979 \times 10^{-9}$$

- Para $\alpha = 0.05$, se rechaza H_0 . Por lo tanto, se puede afirmar que existe una efecto significativo del número de cilindros en la eficiencia esperada.

Ejemplo

```
reg = lm(mpg~cyl,mtcars)
summary(reg)
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  26.6636      0.9718  27.437  < 2e-16 ***
## cyl6         -6.9208      1.5583  -4.441  0.000119 ***
## cyl8        -11.5636      1.2986  -8.905  8.57e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.223 on 29 degrees of freedom
## Multiple R-squared:  0.7325, Adjusted R-squared:  0.714
## F-statistic: 39.7 on 2 and 29 DF, p-value: 4.979e-09
```

- De la salida en R, podemos observar que la información para realizar la prueba de hipótesis de significancia de la regresión se encuentra disponible en la última línea.

Intervalo de confianza para la respuesta media

- Respuesta media para un nivel $\mathbf{x}_0 = (1, x_{01}, \dots, x_{0k})^\top$ de la covariable:

$$y_{x_0} = E(Y \mid X = x_0)$$

- Estimador puntual:

$$\hat{y}_{x_0} = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \dots + \hat{\beta}_k x_{0k}$$

- Error estándar:

$$\widehat{EE}(y_{x_0}) = \hat{\sigma} \left[\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 \right]^{1/2}$$

- Intervalo de confianza

$$IC(y_{x_0}) = \hat{y}_{x_0} \mp t_{1-\frac{\alpha}{2}}(n-p) \widehat{EE}(\hat{y}_{x_0})$$

Intervalo de predicción

- Respuesta para un nivel x_0 de la covariable: $y(x_0)$

- Estimador puntual:

$$\hat{y}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 x_0$$

- Error estándar:

$$\widehat{EE}(\hat{y}_{x_0}) = \hat{\sigma} \left[1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0 \right]^{1/2}$$

- Intervalo de predicción

$$IC(y(x_0)) = \hat{y}(x_0) \mp t_{1-\frac{\alpha}{2}}(n-p) \widehat{EE}(\hat{y}(x_0))$$

Ejemplo

- Estimar un IC al 95% para la eficiencia media de los automóviles con potencia del motor de 150 hp y un peso de 3 mil libras.
- Estimador puntual:

$$\hat{y}_{x_0} = \hat{\beta}_0 + \hat{\beta}_1 \times 150 + \hat{\beta}_2 \times 3 = 20.8$$

- Error estándar:

$$\widehat{EE}(\hat{y}_{x_0}) = \hat{\sigma} \left[\mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0^\top \right]^{1/2} = 0.485$$

- Intervalo de confianza

$$IC(y_{x_0}) = \hat{y}_{x_0} \pm t_{1-\frac{\alpha}{2}}(29) \widehat{EE}(\hat{y}_{x_0}) = 20.8 \pm 2.045 \times 0.485 = [19.835, 21.820]$$

Ejemplo

```
# Estimar regresión; retirar coeficientes; matriz X
reg = lm(mpg~hp+wt,mtcars); b = coef(reg); X = model.matrix(reg)
# IC
x0 = c(1,150,3)
(mu_hat = x0%*%b)
```

```
##          [,1]
## [1,] 20.82784
```

```
sigma = summary(reg)$sigma
(EE = sigma*sqrt(t(x0)%*%solve(t(X)%*%X)%*%x0))
```

```
##          [,1]
## [1,] 0.4851681
```

```
(t = qt(0.975,29))
```

```
## [1] 2.04523
```

```
(IC = c(LI=mu_hat-t*EE,LS=mu_hat+t*EE))
```

```
##      LI      LS
## 19.83556 21.82012
```

Ejemplo

```
reg = lm(mpg~hp+wt,mtcars)
predict(reg,data.frame(hp=150,wt=3),interval="confidence")
```

```
##           fit           lwr           upr
## 1 20.82784 19.83556 21.82012
```

- Con un 95% de confianza la eficiencia media de los automóviles con potencia del motor de 150 hp y un peso de 3 mil libras estará entre 19.8 y 21.8 mpg.

Ejemplo

- Estimar un intervalo de predicción al 95% para la eficiencia de un automóvil con potencia del motor de 150 hp y un peso de 3 mil libras.
- Estimador puntual:

$$\hat{y}(x_0) = \hat{\beta}_0 + \hat{\beta}_1 \times 150 + \beta_2 \times 3 = 20.8$$

- Error estándar:

$$\widehat{EE}(\hat{y}(x_0)) = \hat{\sigma} \left[1 + \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0^\top \right]^{1/2} = 2.638$$

- Intervalo de predicción

$$IC(y(x_0)) = \hat{y}(x_0) \mp t_{1-\frac{\alpha}{2}}(29) \widehat{EE}(\hat{y}(x_0)) = 20.8 \mp 2.045 \times 2.638 = [15.431, 26.2]$$

Ejemplo

```
# Estimar regresión; retirar coeficientes; matriz X
reg = lm(mpg~hp+wt,mtcars); b = coef(reg); X = model.matrix(reg)
# IC
x0 = c(1,150,3)
(mu_hat = x0%*%b)
```

```
##          [,1]
## [1,] 20.82784
```

```
sigma = summary(reg)$sigma
(EE = sigma*sqrt(1+t(x0)%*%solve(t(X)%*%X)%*%x0))
```

```
##          [,1]
## [1,] 2.638403
```

```
(t = qt(0.975,29))
```

```
## [1] 2.04523
```

```
(IC = c(LI=mu_hat-t*EE,LS=mu_hat+t*EE))
```

```
##          LI          LS
## 15.43169 26.22398
```

Ejemplo

```
reg = lm(mpg~hp+wt,mtcars)
predict(reg,data.frame(hp=150,wt=3),interval="prediction")
```

```
##           fit           lwr           upr
## 1 20.82784 15.43169 26.22398
```

- Con un 95% de confianza la eficiencia de un automóvil con potencia del motor de 150 hp y un peso de 3 mil libras estará entre 15.4 y 26.2 mpg.

Ejemplo

Ejemplo

Considerando los datos `mtcars` de R, estime un modelo para estimar la eficiencia en consumo de combustible (`mpg`) en función de la potencia del motor (`hp`), del peso del automóvil en miles libras (`wt`) y del tipo de caja de cambio (`am`).

- a) Interprete los coeficientes.
- b) Realice una prueba de hipótesis para la significación del coeficiente del tipo de caja de cambio. Comente sus resultados.
- c) Compare este modelo con los modelos anteriores ¿Qué modelo es mejor para estimar la eficiencia?